Fouille de Données

Data Mining

Introduction Générale

Plan du cours

1. Définitions et généralités
2. Modèles de Processus de Data Mining
3. Les types de données à fouiller
4. Les tâches du data mining

Fouille de Données
Data Mining

« L'humanité produit autant de données en deux jours qu'elle ne l'a fait en milliers d'années. »

Fouille de Données

?

Donnée ➔ Information ➔ Connaissance

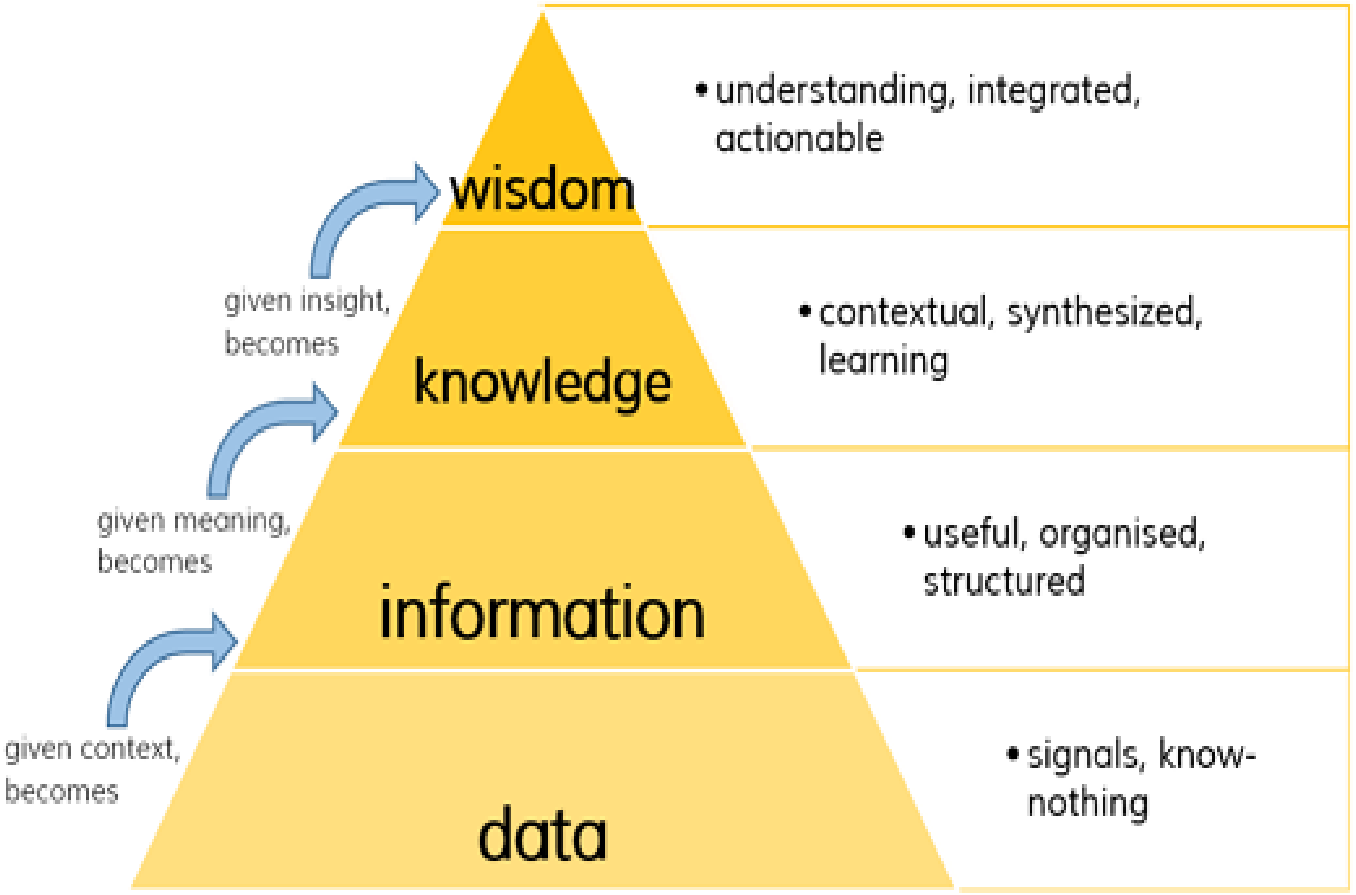

Donnée ➔ Information ➔ Connaissance

Exemple :

- ✓ Le nombre d'accidents n'augmente pas quand il fait mauvais.
- ✓ 1217 accidents enregistrés durant le mois de mars.
- ✓ Une augmentation de 240% du nombre d'incidents par rapport au mois précédent.

Donnée ➔ Information ➔ Connaissance

Exemple :

- ✓ Le nombre d'accidents n'augmente pas quand il fait mauvais.

Connaissance

- ✓ 1217 accidents enregistrés durant le mois de mars.

Donnée

- ✓ Une augmentation de 140% du nombre d'incidents par rapport au mois précédent.

Information

Donnée ➔ Information ➔ Connaissance

Donnée : est le résultat direct d'une mesure, collecte, observation, etc.

Information : est une donnée à laquelle un contexte et un sens lui ont été donnés.

Connaissance : est le résultat d'une réflexion sur les informations analysées.
Est une information à la laquelle une signification lui a été donnée.

Faire parler les données
Pour une meilleure prise de décisions

Fouille de Données

?

Fouille de Données – Data Mining

Quoi ? Explorer, rechercher, et extraire des informations et des connaissances à partir des données.

Laquelle ? Les pertinentes d'entres elles pouvant aider à comprendre les données ou à prédire le comportement des données futures.

Depuis où ? Entrepôts de données (data warehouse), des bases de données distribuées, Internet.

Avec quoi ? Algorithmes, méthodes, et techniques de l'informatique, l'IA, les statistiques, etc.

Comment ? Ces connaissances (qui doivent être validées) sont exprimées sous forme de modèles maths, logiques, rapports, graphiques, tendances, etc.

Pourquoi ? Condition d'évolution. Inférer des lois. Aboutir à des connaissances opérationnelles/actionnables nécessaires à la prise de décisions.

Fouille de Données – Data Mining

Confusion entre :

- ✓ Data Mining, et
- ✓ Extraction des connaissances à partir des données - ECD
- ✓ Knowledge Discovery in Databases - KDD

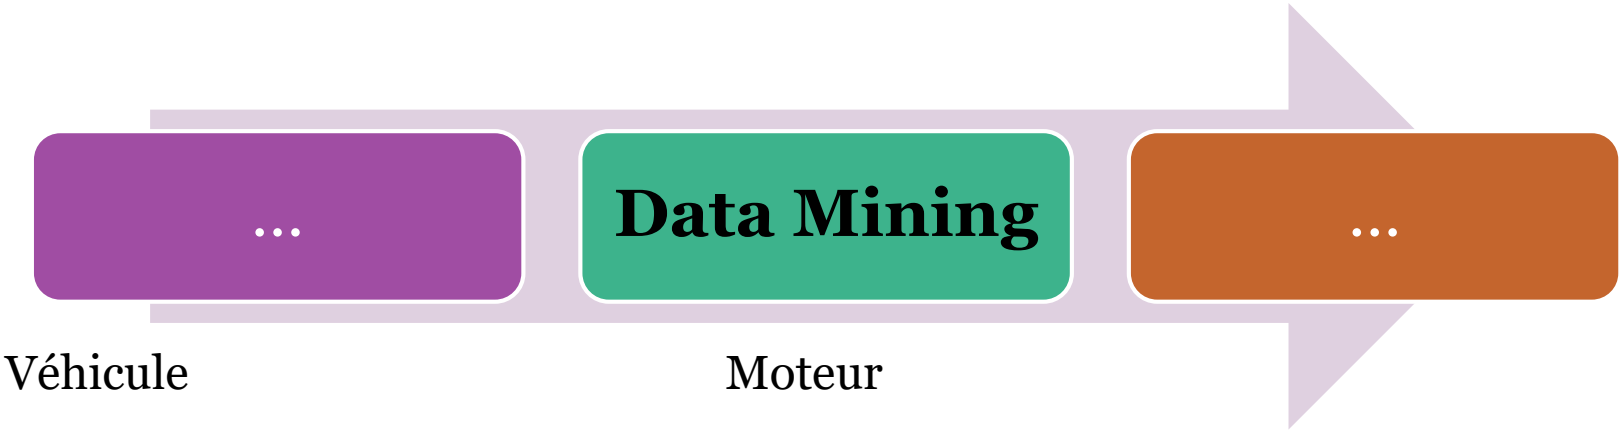

Fouille de Données – Data Mining

Techniques :

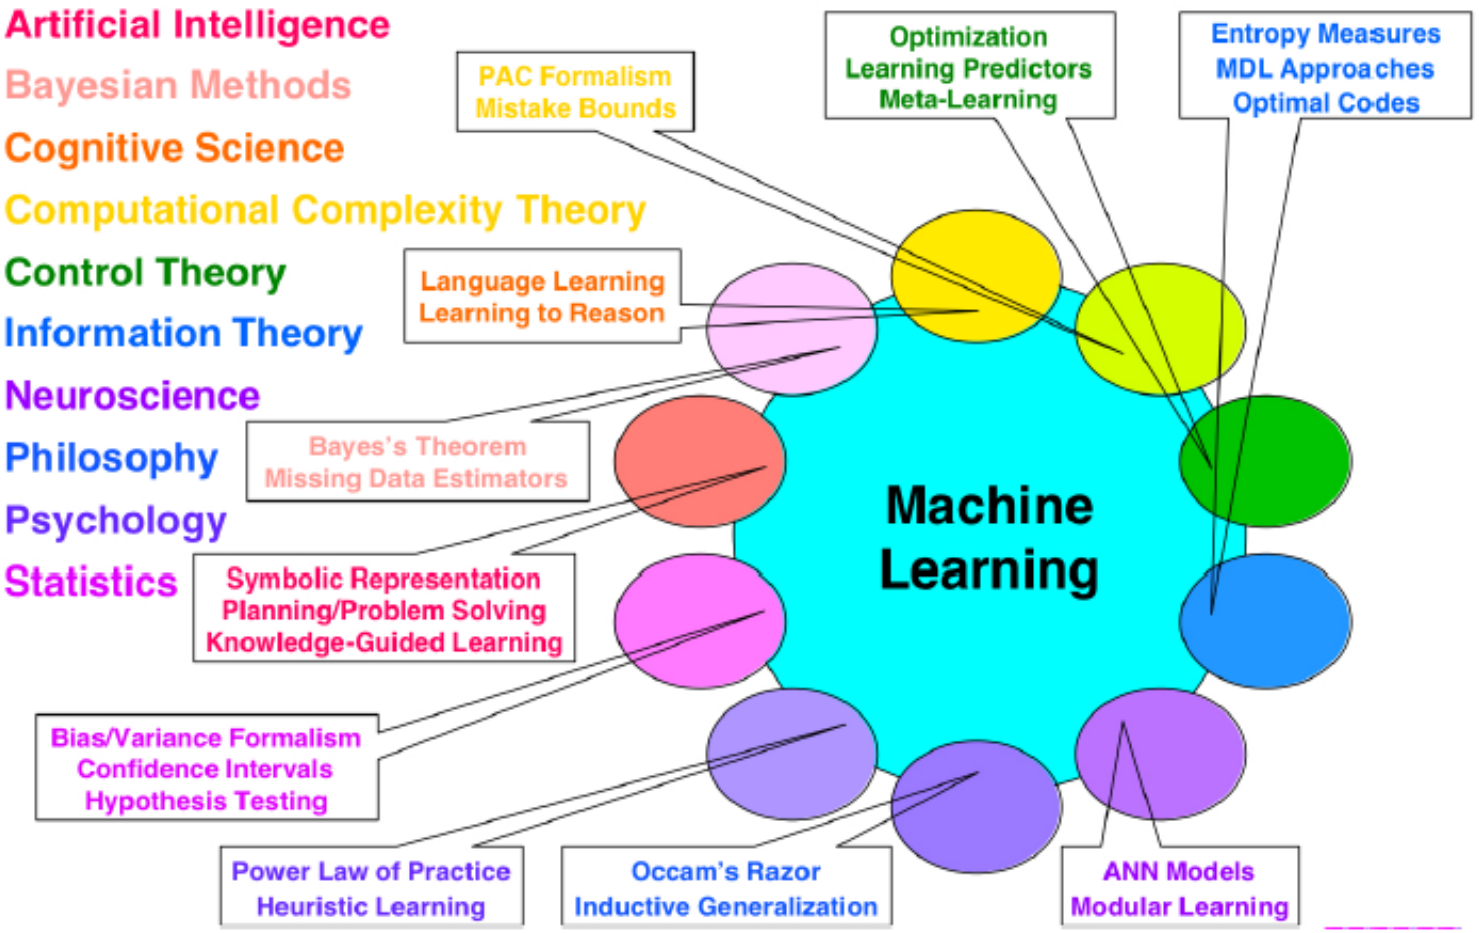

Fouille de Données – Data Mining

Techniques :

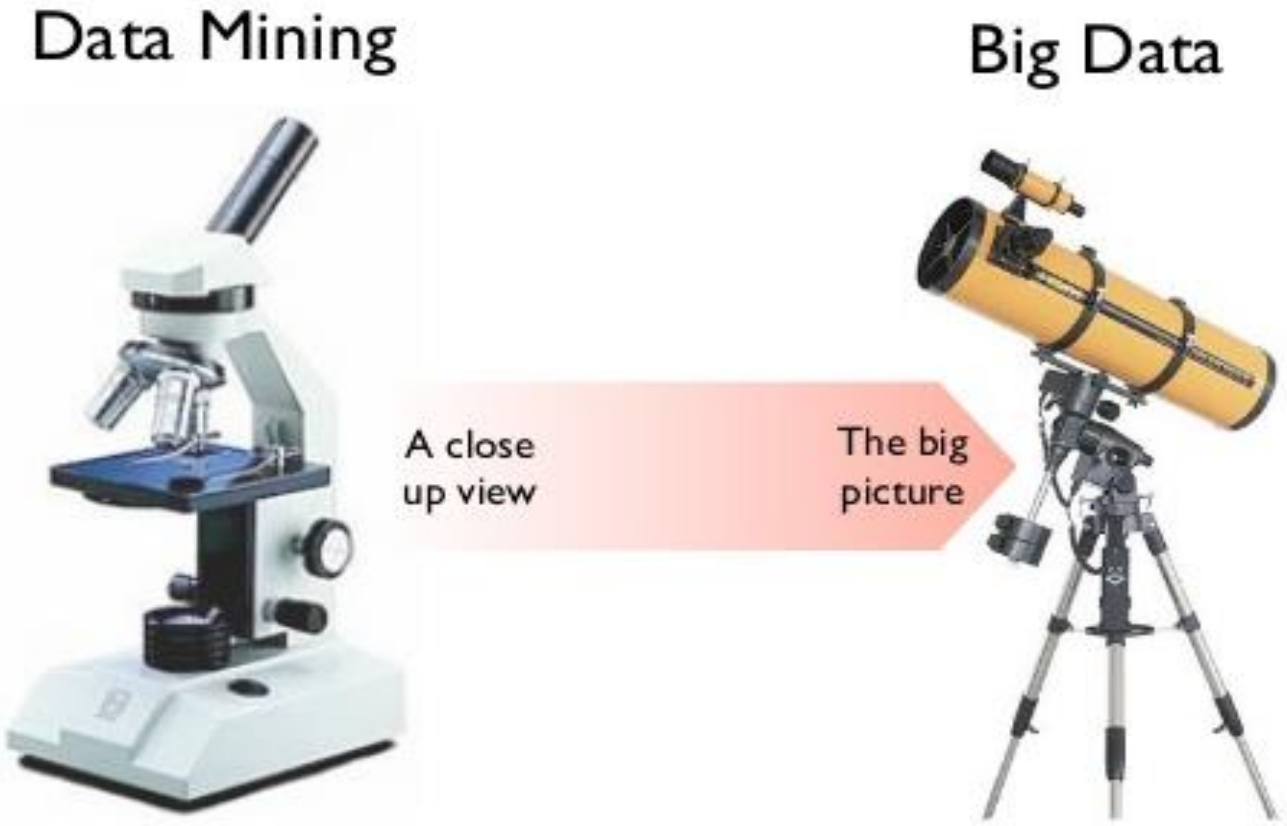

http://stackoverflow.com/questions/22419958/what-is-the-difference-between-big-data-and-data-mining/22421731#22421731

Fouille de Données – Data Mining

Domaines d'utilisation :

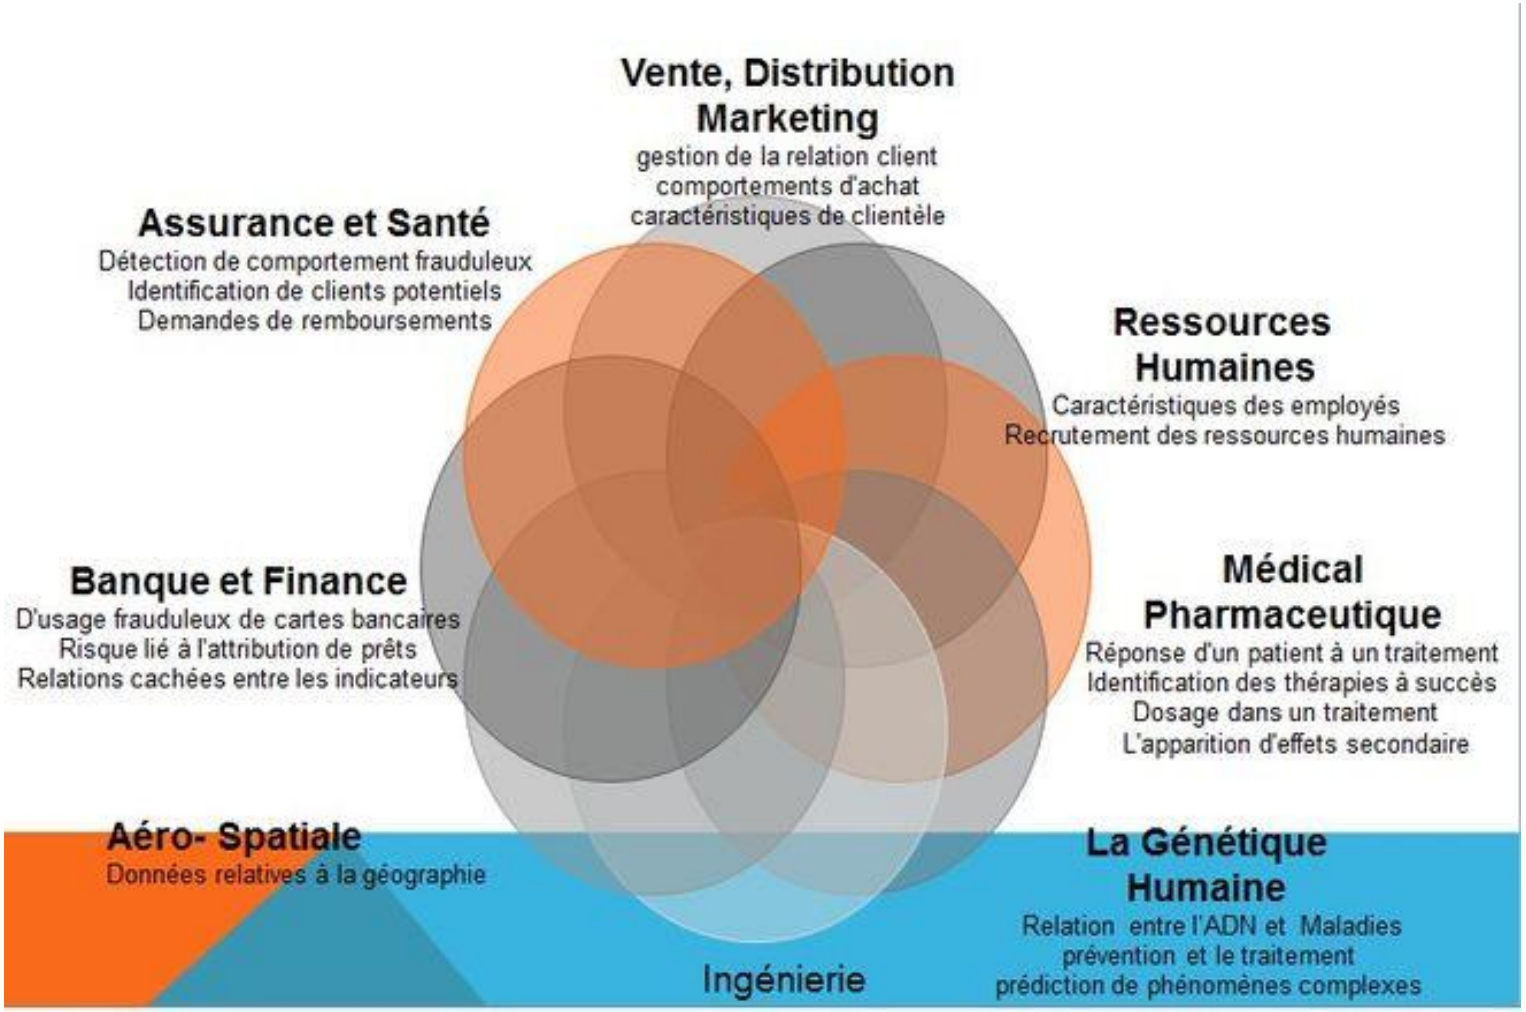

Fouille de Données – Data Mining

Domaines d'utilisation :

- ✓ La gestion de la relation client qui consiste à analyser le comportement de la clientèle pour mieux la fidéliser et lui proposer des produits adaptés.
- ✓ organisation des rayonnages dans les supermarchés.
- ✓ Organisation de campagne de publicité, emailing, promotions, etc.
- ✓ Gestion du risque lié à l'attribution de prêts par le Credit Scoring.
- ✓ La détection des fraudes fiscales.
- ✓ Détection d'usage frauduleux de cartes bancaires.
- ✓ Diagnostiques médicaux, identification des thérapies à succès, etc.
- ✓ Web mining, text mining - indexation, image-mining, etc.

Fouille de Données – Data Mining

Contexte :

- ✓ “We are living in the ~~information~~ data age” .
- ✓ La puissance croissante des nouvelles technologies, ont contribué fortement à l’augmentation des collectes des données, la manipulation, et la capacité de stockage.
- ✓ Les données se sont multipliées en taille, en format, et en complexité.
- ✓ Certains experts estiment que le volume des données double tous les ans.
- ✓ L’humanité produit autant de données en deux jours qu’elle ne l’a fait en milliers d’années.
- ✓ Même la façon de les interroger devient données : requêtes sur BDD, historique de navigation sur le Web, recherches sur Google, etc.

Fouille de Données – Data Mining

Besoins:

- ✓ The information paradox. - Timo Lüge
- ✓ Que doit-on faire avec des données coûteuses à collecter et à conserver ?
- ✓ Le besoin des entreprises de valoriser les données qu'elles accumulent dans leurs bases qui croissent de manière exponentielle.
- ✓ Le data mining permet d'exploiter ces données au profit de l'activité de l'entreprise.
- ✓ Le data mining permet aussi d'augmenter le retour sur investissement des systèmes d'information.
- ✓ Data mining = Moteur essentiel de du processus décisionnel.

Extraction de Connaissances à partir des Données

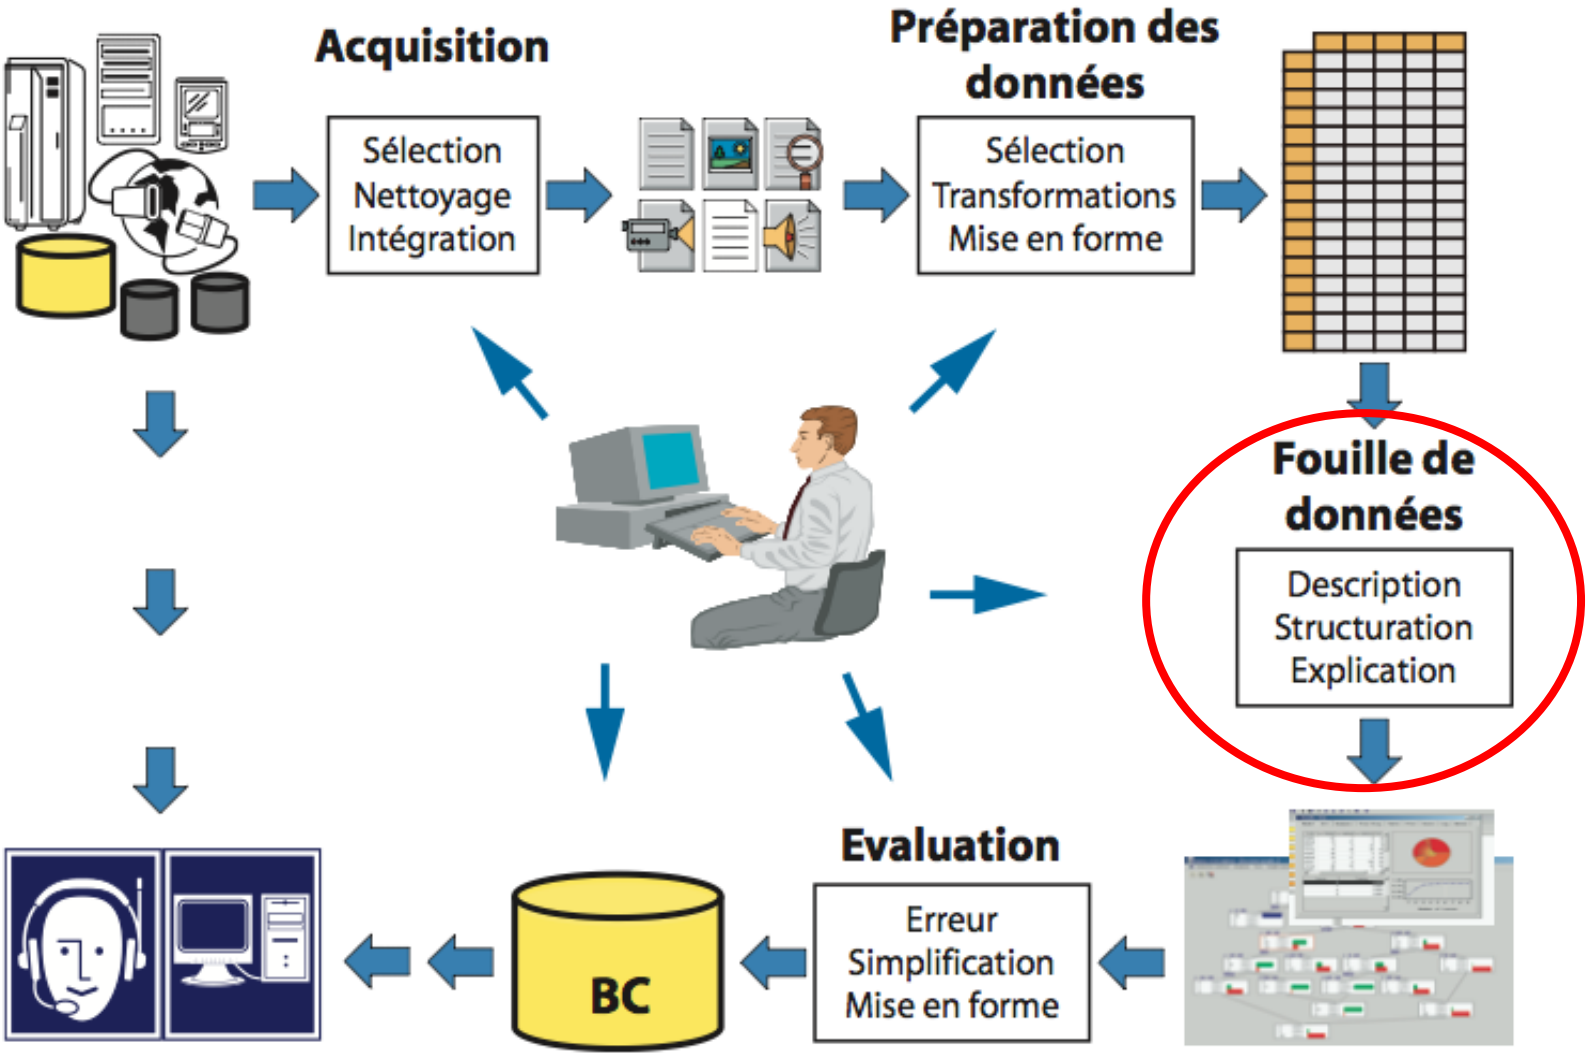

Modèles de Processus de Data Mining

KDD

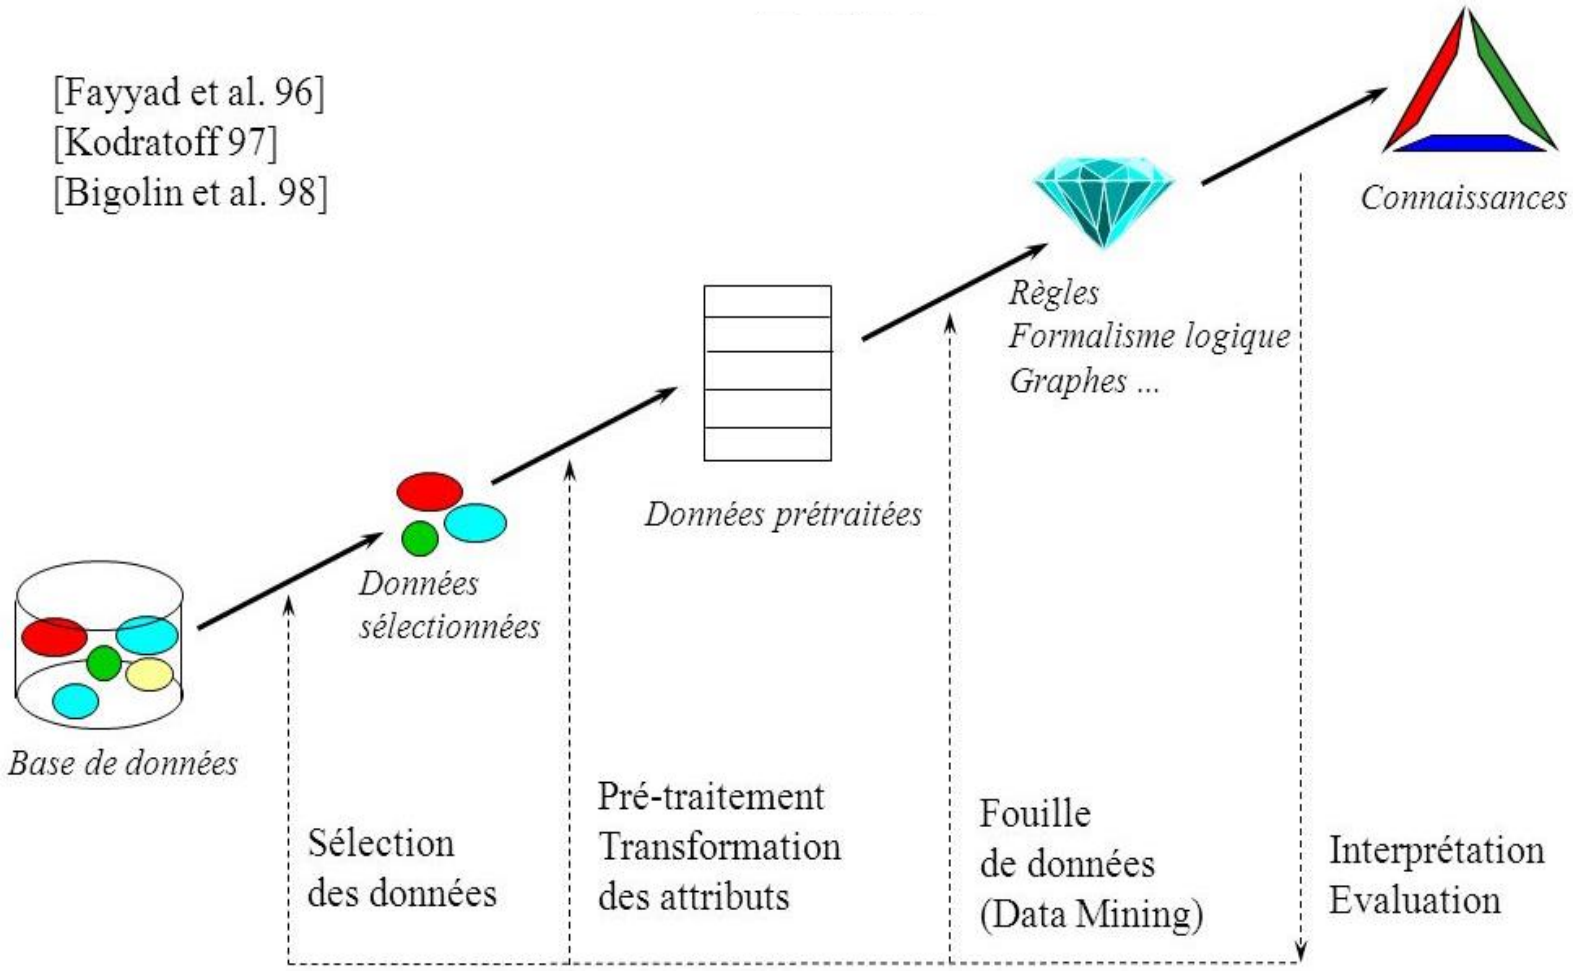

Modèles de Processus de Data Mining

Standard **CRISP-DM** : Cross-Industry Standard Process for Data Mining

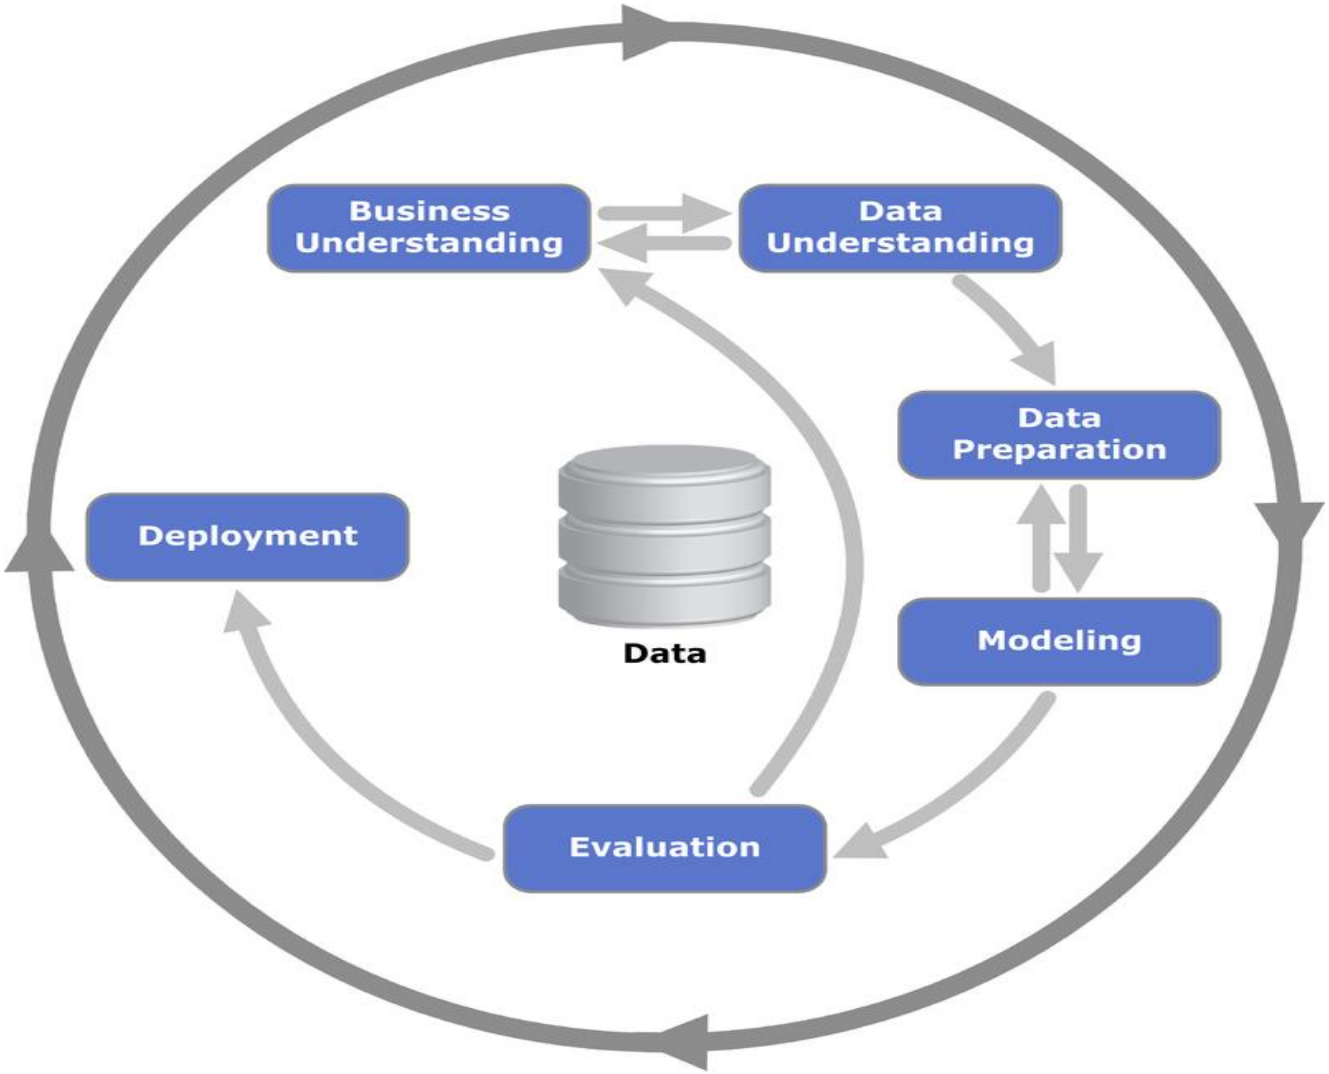

Modèles de Processus de Data Mining

Standard **CRISP-DM** : Cross-Industry Standard Process for Data Mining

1 - Définition et compréhension du problème

- ✓ Comprendre les objectifs et les exigences du projet Data Mining.
- ✓ Indispensabilité de comprendre le domaine à explorer.
- ✓ Pour un meilleur choix de la technique, et donc de son résultat fiable.
- ✓ Meilleure explication et évaluation des résultats obtenus.

Modèles de Processus de Data Mining

Standard **CRISP-DM** : Cross-Industry Standard Process for Data Mining

2 – Compréhension des données

- ✓ Les collecter et comprendre leur signification.
- ✓ Déterminer précisément les données à analyser et à identifier la qualité des données.
- ✓ Identifier et sélectionner les données à utiliser selon le problème défini.
- ✓ Ces données n'ont pas toujours le même format, le même type, et la même structure. ((textes, BDD, pages web, images, video, ...etc)

Modèles de Processus de Data Mining

Standard **CRISP-DM** : Cross-Industry Standard Process for Data Mining

3 – Prétraitement des données

✓ Regroupe les activités liées à la construction de l'ensemble précis des données à analyser à partir des données brutes.

✓ Souvent, données bruitées (erreurs de frappe, erreurs système, …), incohérentes, anomalies, etc.

✓ Inclue le classement des données en fonction de critères choisis, le nettoyage des données, unification des intervalles, lissage, réduction, etc.

✓ Une fois les données collectées, nettoyées et prétraitées on les appelle entrepôt de données.

Modèles de Processus de Data Mining

Standard **CRISP-DM** : Cross-Industry Standard Process for Data Mining

4 – Modélisation

- ✓ Différents algorithmes et techniques sont sélectionnés et appliqués.
- ✓ Leurs paramètres sont étalonnés aux valeurs optimales.
- ✓ Choisir la bonne technique pour extraire les connaissances.

Modèles de Processus de Data Mining

Standard **CRISP-DM** : Cross-Industry Standard Process for Data Mining

5 – Evaluation

- ✓ Vise à vérifier le modèle ou les connaissances obtenues afin de s'assurer qu'ils répondent aux objectifs formulés au début du processus.

- ✓ Elle contribue aussi à la décision de déploiement du modèle, ou si besoin est, à son amélioration.

Modèles de Processus de Data Mining

Standard **CRISP-DM** : Cross-Industry Standard Process for Data Mining

6 – Déploiement

- ✓ Son objectif est de mettre la connaissance obtenue par la modélisation, dans une forme adaptée et l'intégrer au processus de prise de décision.
- ✓ Aider à la prise de décision en fournissant des modèles et des interprétations compréhensibles aux utilisateurs.
- ✓ Le déploiement peut aller, selon les objectifs, de la simple génération d'un rapport décrivant les connaissance obtenues jusqu'à la mise en place d'une application.

Fouille de Données

Quel type?

Quel type de données à fouiller ?

- Données à explorer = Un ensemble d'échantillons / enregistrements
- Echantillon = ensembles d'attributs / champs

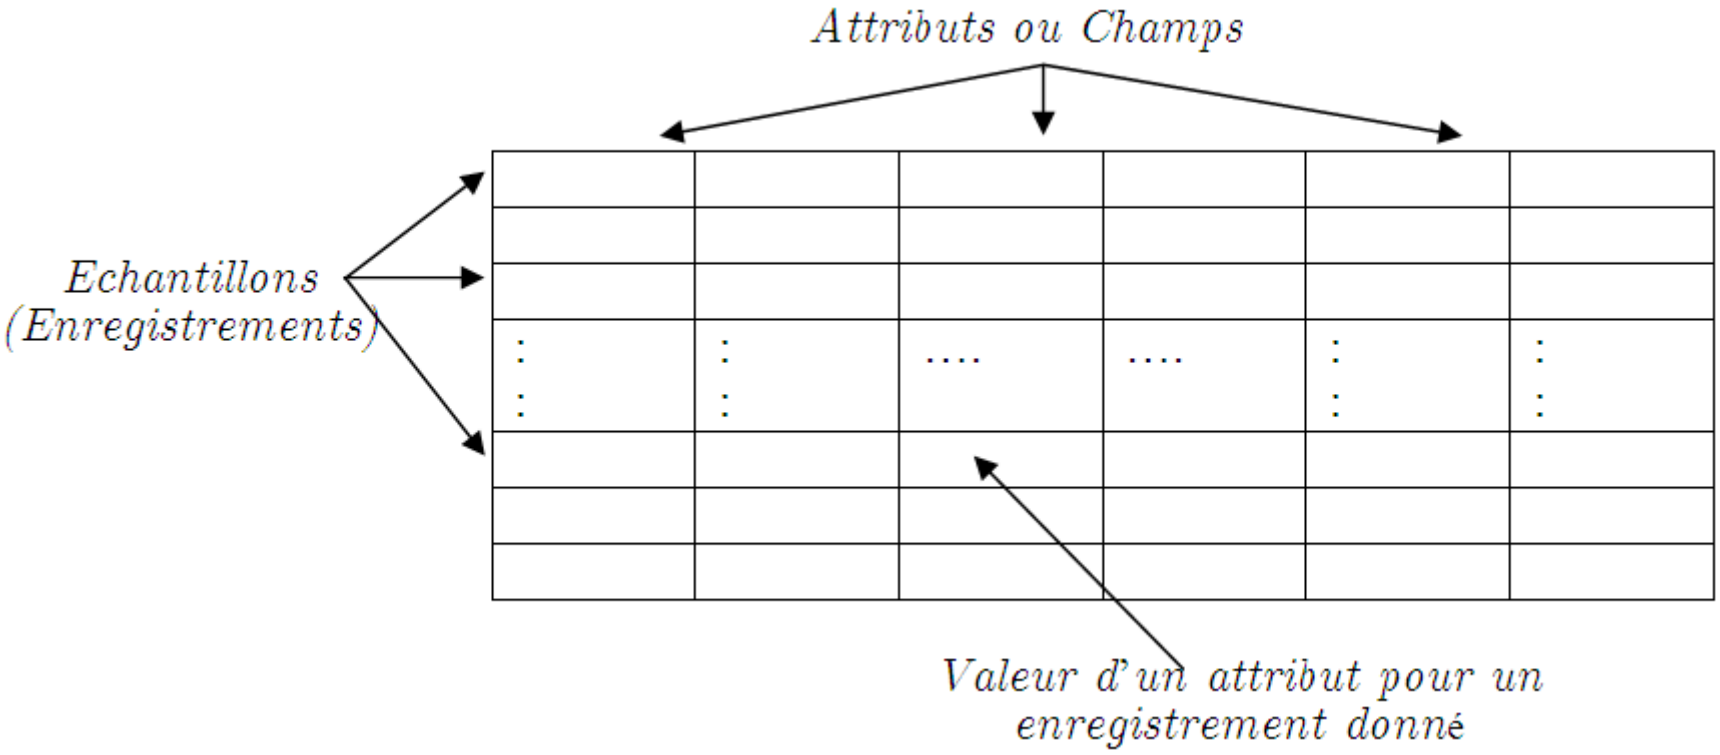

Quel type de données à fouiller ?

- Une donnée est :

  - ✓ Enregistrement au sens des bases de données.
  - ✓ Individu en statistiques.
  - ✓ Instance en POO.
  - ✓ Etc.

- Une donnée est caractérisée par :

  - ✓ Champs en bases de données.
  - ✓ Caractéristiques statistiques.
  - ✓ Attributs en POO.

Quel type de données à fouiller ?

Deux types d'attributs :

1. Numériques – Continus:

Comportent les variables réelles ou entières tel que la longueur, le poids, etc.

Relation d'ordre ($5 < 7$).

Mesure de distance.

Calcul de moyenne, min, max, etc.

2. Catégoriels - Qualitatifs:

Ex : couleur, code postal, ou groupe sanguin.

Deux variables catégorielles ne peuvent être qu'égales ou différentes.

Quel type de données à fouiller ?

Qualité des données à fouiller :

- ✓ Données précises : noms écrits correctement, valeurs dans les bons intervalles.
- ✓ Données enregistrées dans le bon format : numérique/caractère, entière /réelle, etc.
- ✓ Redondance minimisée, voire éliminée.

Préparation des données à fouiller :

- ✓ Manuelle : nombre limite d'enregistrements.
- ✓ Semi-automatique : nombre moyen d'enregistrements.
- ✓ Automatique : immenses bases de données.

Fouille de Données – Data Mining

Objectifs de la matière

SAVOIR – PREDIR/DECOUVRIR - DECIDER

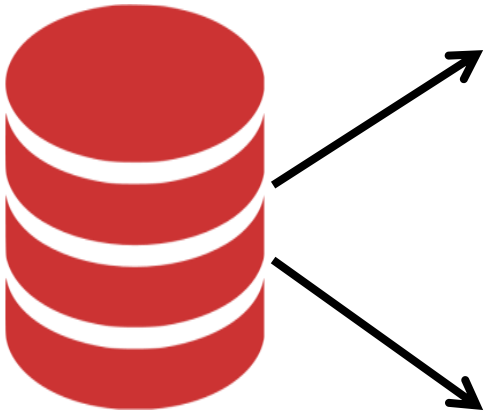

Entrées

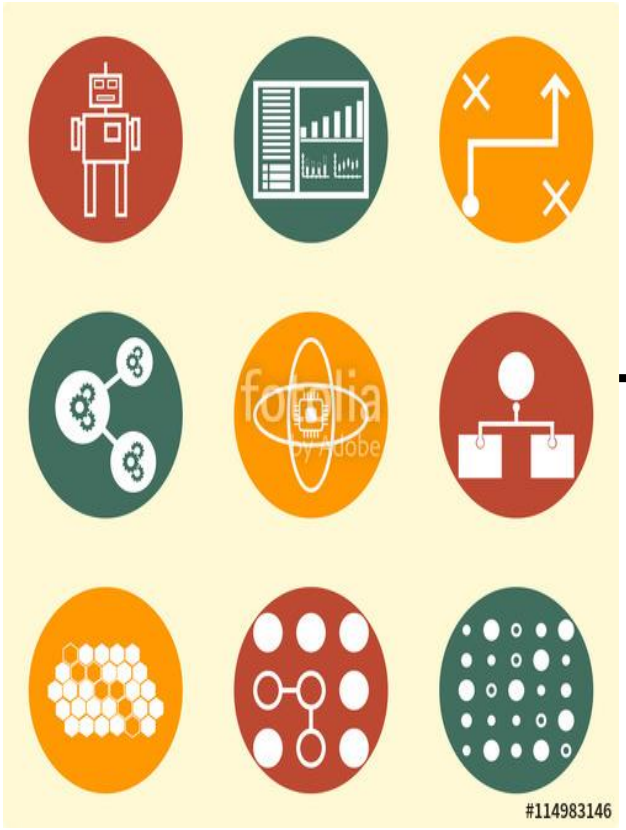

Traitement

Sorties

Fouille de Données – Data Mining

Objectifs de la Matière

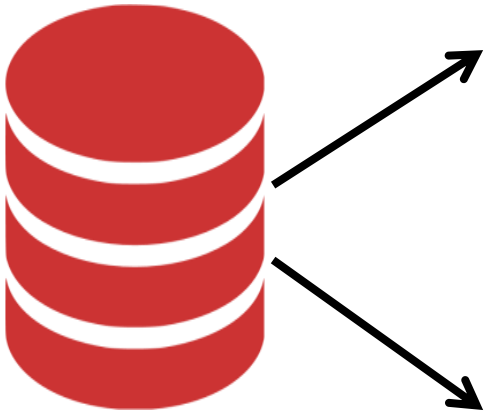

Données

Traitement

Connaissances

Fouille de Données – Data Mining

Objectifs de la matière

La fouille de données vise à découvrir, dans les grandes quantités de données, les informations importantes qui peuvent aider à comprendre les données ou à prédire Le comportement des données futures.

Le but de ce cours est d'initier les apprenants aux différents algorithmes et techniques utilisés en fouille de données.

Pré requis recommandés **:** Connaissances: *algorithmique, algèbre linaire*

Unité d'enseignement : UEM21
Crédit : 5
Coefficient : 3
Mode d'évaluation : Examen, contrôle continu TD et TP.

Fouille de Données – Data Mining

Contenu de la matière :

1) Introduction générale
2) Recherche des modèles fréquents et des règles d'associations
3) Classification
4) Régression
5) Clustering

Les tâches du Data Mining

Cinq tâches principales :

- ✓ La classification.
- ✓ L'estimation/régression.

Méthodes d'apprentissage supervisé

- ✓ Le groupement par similitude (règles d'association).
- ✓ L'analyse des clusters.

Méthodes d'apprentissage non supervisé

Les tâches du Data Mining

La classification :

Consiste à étudier les caractéristiques d'un nouvel objet pour l'attribuer à une classe prédéfinie.

Deux phases :

1. Apprentissage : apprend du jeu d'apprentissage et construit un modèle.
2. Classification : le modèle appris est employé pour classier de nouveaux objets.

La régression :

Similaire à la classification à part que la variable de sortie est numérique plutôt que catégorique.

Ex : tension d'un patient selon âge, poids, etc.

Les tâches du Data Mining

Le groupement par similitude :

Consiste à déterminer quels attributs "vont ensemble".

Les règles d'associations sont de la forme "Si <antécédent>, alors <conséquent>".

Clustering :

Regroupement en groupes d'objets similaires.

Segmenter la totalité de données en des sous groupes relativement homogènes.

Maximiser l'homogénéité à l'intérieur de chaque groupe et la minimiser entre les différents groupes.

Fouille de Données – Data Mining

Contenu de la matière :

TP : Suite de logiciels libres d'apprentissage et de data mining **Weka et Python**.

Weka : pour Waikato Environment for Knowledge Analysis.

Un projet open source qui implémente plusieurs techniques de fouille de données et de prétraitement, issues de la communauté apprentissage automatique. + API Java

Scikit-learn est une bibliothèque libre Python destinée à l'apprentissage automatique.

Quiz

Pour aller plus loin et tester ses acquis :

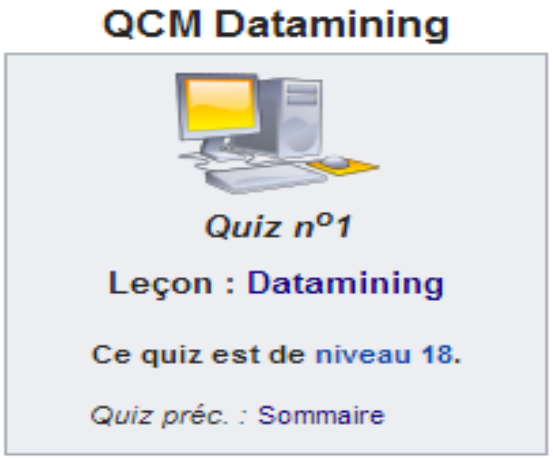

https://fr.wikiversity.org/wiki/Datamining/Quiz/QCM_Datamining

Ressources

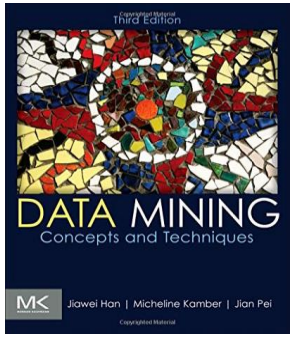

Data Mining : concepts and techniques, 3rd Edition

- ✓ Auteur : Jiawei Han, Micheline Kamber, Jian Pei
- ✓ Éditeur : Morgan Kaufmann Publishers
- ✓ Edition : Juin 2011 - 744 pages - ISBN 9780123814807

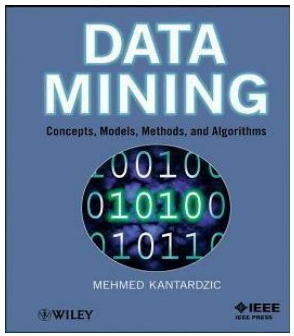

Data Mining : concepts, models, methods, and algorithms

- ✓ Auteur : Mehmed Kantardzi
- ✓ Éditeur : John Wiley & Sons
- ✓ Edition : Aout 2011 – 552 pages - ISBN : 9781118029121

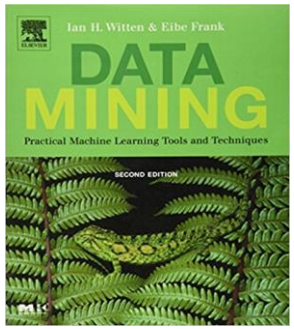

Data Mining: Practical Machine Learning Tools and Techniques

- ✓ Auteur : Ian H. Witten & Eibe Frank
- ✓ Éditeur : Morgan Kaufmann Publishers
- ✓ Edition : Juin 2005 - 664 pages - ISBN : 0-12-088407-0

Ressources

Cours – Abdelhamid DJEFFAL – Fouille de données avancée

- ✓ www.abdelhamid-djeffal.net

WekaMOOC – Ian Witten – Data Mining with Weka

- ✓ https://www.youtube.com/user/WekaMOOC/featured

Cours - Laboratoire ERIC Lyon - DATA MINING et DATA SCIENCE

- ✓ https://eric.univ-lyon2.fr/~ricco/cours/supports_data_mining.html

Gregory Piatetsky-Shapiro - KDNuggets

- ✓ http://www.kdnuggets.com/