Fouille de Données

Data Mining

Classification - Partie 1

Plan du cours

1. Contexte
2. Organisation
3. Evaluation du modèle
4. Les arbres de décision

Contexte

SAVOIR - PREDIRE - DECIDER

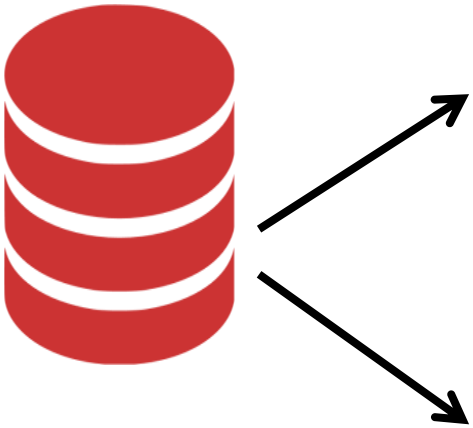

Données

Algorithmes

Connaissances

Contexte

- Supervisée Vs. Non Supervisée (Clustering).

- Classification supervisée : Tâche très importante dans le data mining (Machine Learning).
- Permet d'apprendre des modèles de décision pour prédire/classifier le comportement des exemples futurs.

- Ex: Une tumeur est-elle bénigne ou maligne ?
- Ex: Une transaction carte de crédit est-elle frauduleuse ou non ?
- Ex: Catégorie d'une actualité/news : Sport, Politique, Musique, etc.

Contexte

- La classification supervisée :
- Inférer à partir d'un échantillon d'exemples classés une procédure de classification.
- Effectue la recherche d'une telle procédure selon un **modèle**.
- Modèles basés sur des :
  - hypothèses probabilistes : classifier naïf de Bayes, méthodes paramétriques ;
  - notions de proximité : plus proches voisins ;
  - recherches dans des espaces d'hypothèses : **arbres de décision**, réseaux de neurones.

Organisation

Deux étapes :

1. Apprentissage (entrainement)
2. Classification (Utilisation)

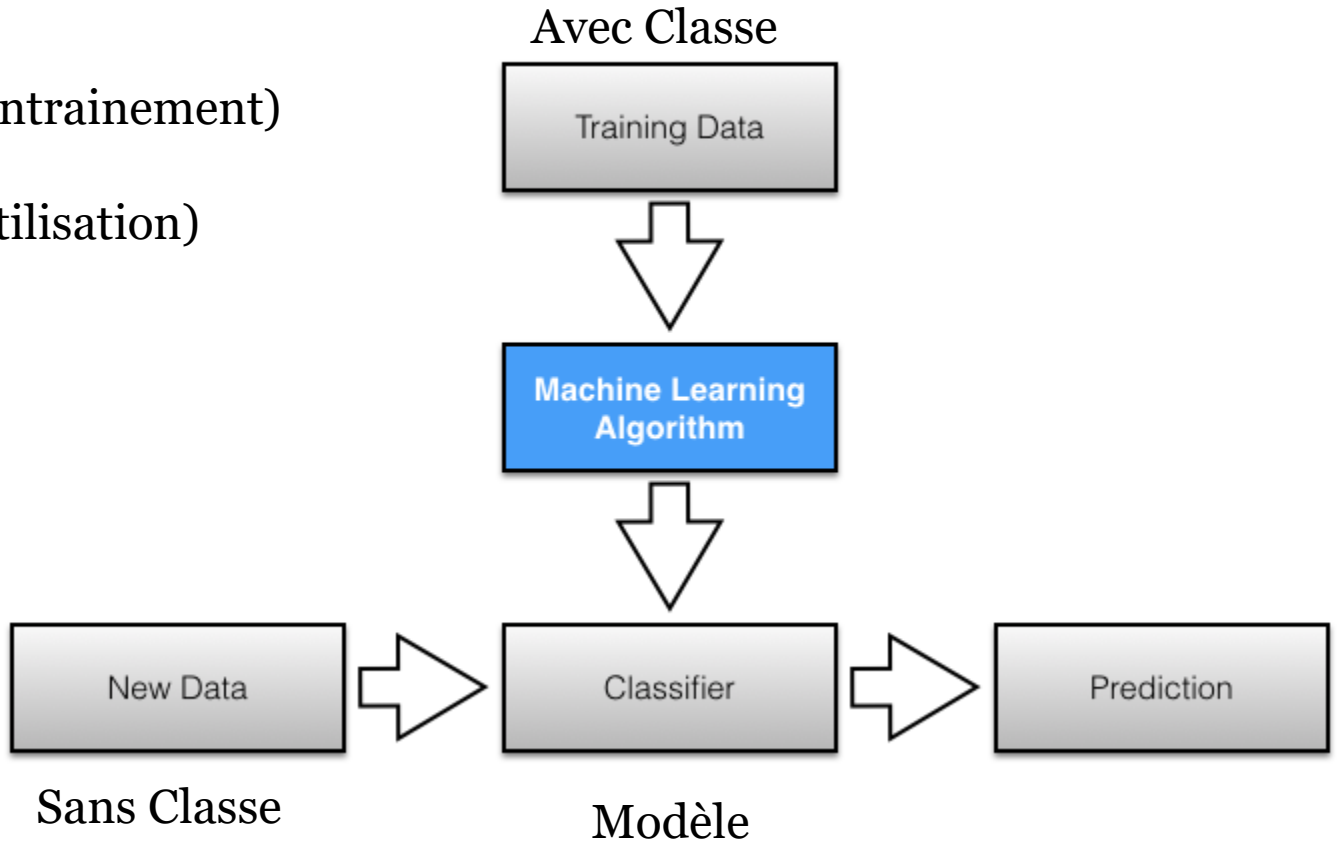

Organisation

- Chaque exemple de l'ensemble d'exemples $\boldsymbol{S}$ est représenté par $\boldsymbol{m}$ attributs et sa classe $\mathbf{y} \in Y$.
- Classe, ou label, ou étiquette.
- Dans la classification, la classe prend sa valeur parmi un ensemble fini.
- Classe = attribut qualitatif.
- $|Y| = 1$: Classification mono-classe
- $|Y| = 2$: Classification binaire
- $|Y| > 2$: Classification multi-classe
- Dans notre cas, on considère que chaque donnée appartient à une et une seule classe.

Organisation

Deux étapes:

1. Apprentissage (entrainement)
2. Classification (Utilisation)

Deux bases d'exemples:

1. Training Set
2. Test Set

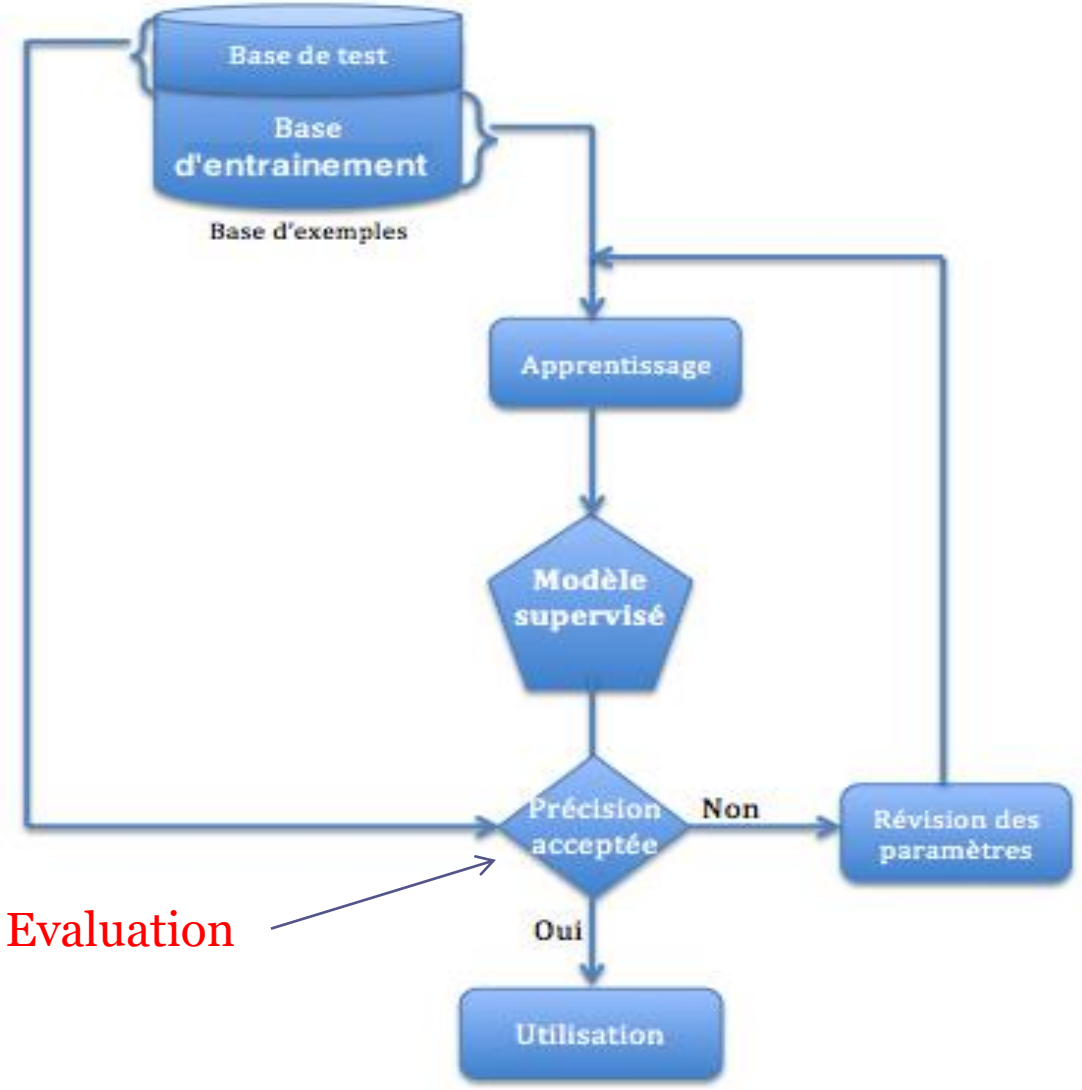

Organisation

Pourquoi deux bases ?

- Les données d'entrainement peuvent contenir des données bruitées ou erronées.
- Des données qui ne représentent pas le cas général tirant le modèle vers leurs caractéristiques.
- Problème de Sur-apprentissage - Overfitting.
- => Utilisation de la base de test.
- La base de test est un ensemble d'exemples ayant les mêmes caractéristiques que ceux de la base d'entrainement et qui sont écartés au départ de l'entrainement pour effectuer les tests.

Organisation

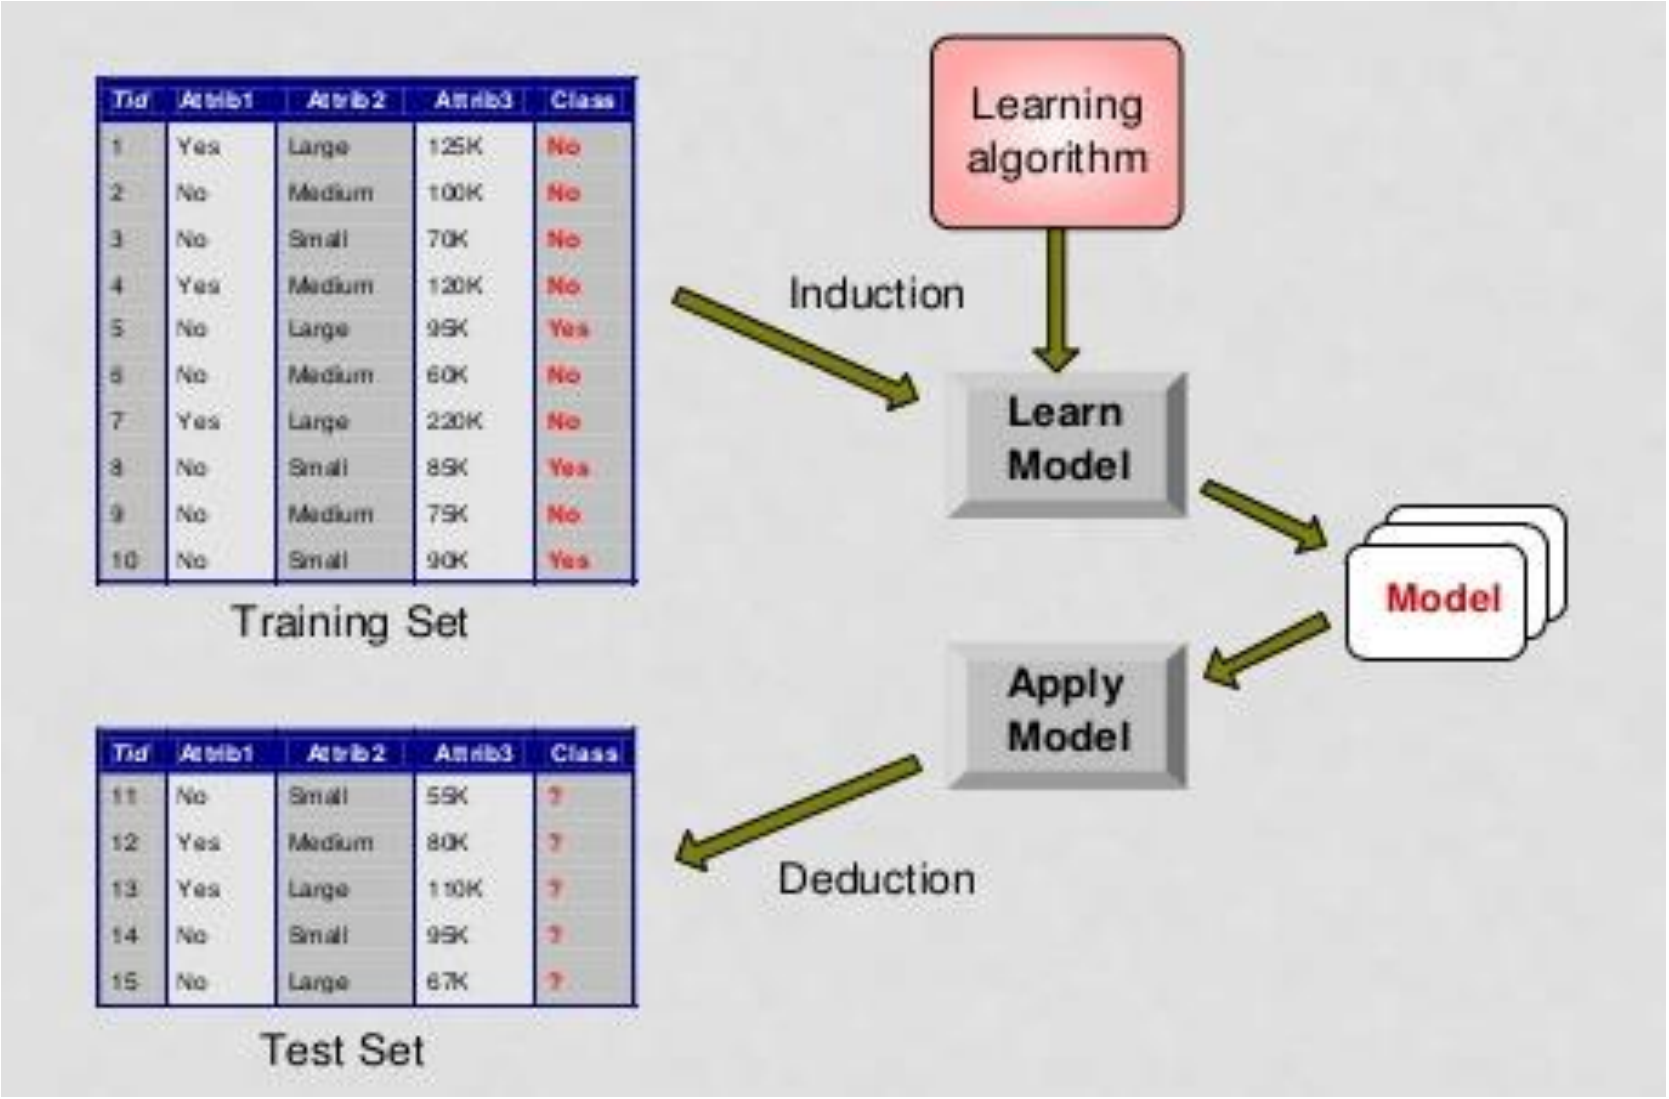

Les arbres de décision

- Méthode très efficace d'apprentissage et de classification supervisés.
- Partitionner un ensemble de données en des groupes les plus **homogènes** possible du point de vue de la classe à prédire.

Arbre
- ✓ Nœud : Test/Attribut
- ✓ Branche: Valeur attribut
- ✓ Feuille : Décision/Classe

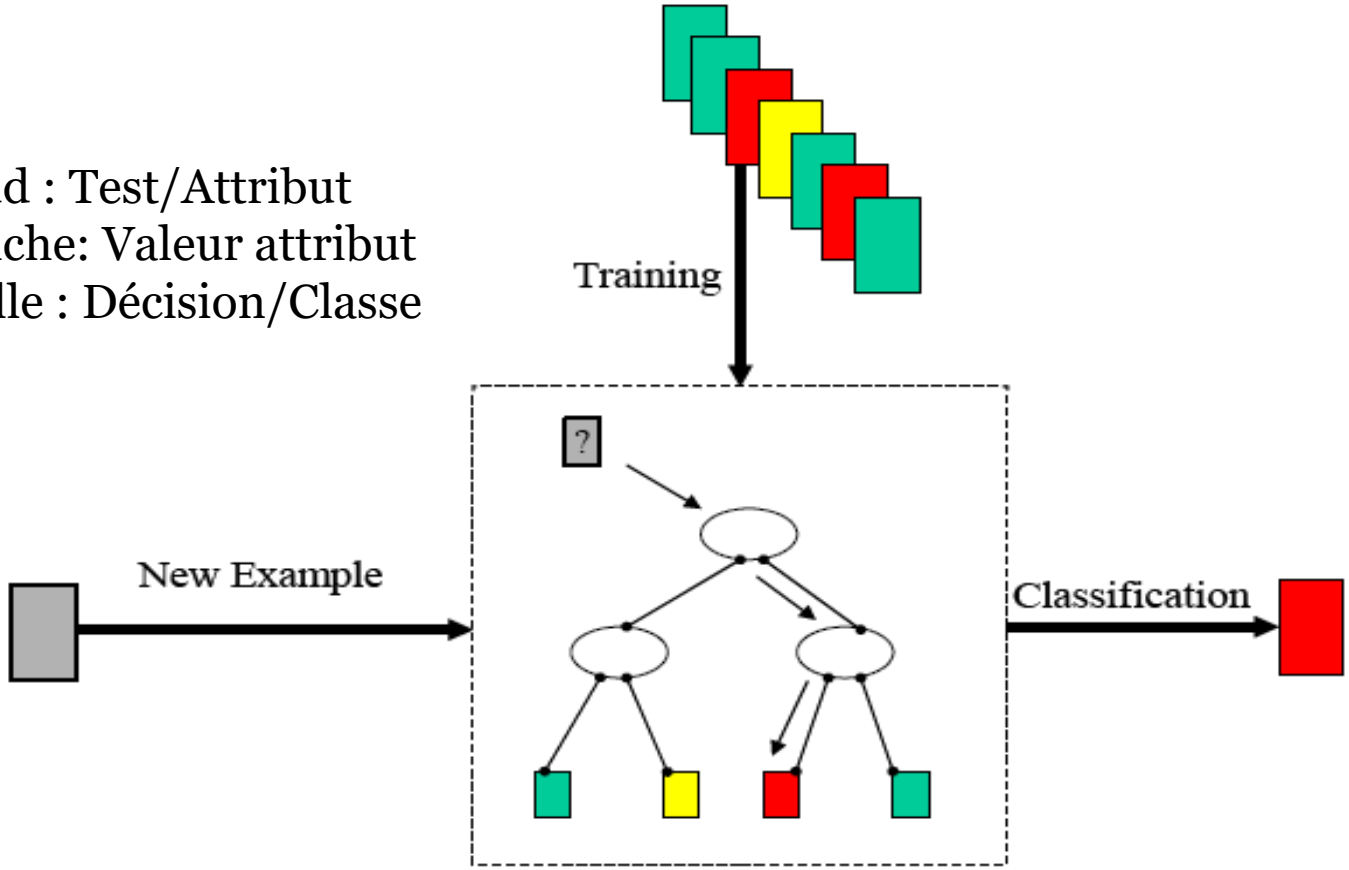

Les arbres de décision

Exemple

Day	Temperature	Outlook	Humidity	Windy	Play Golf?
07-05	hot	sunny	high	weak	no
07-06	hot	sunny	high	strong	no
07-07	hot	overcast	high	weak	yes
07-09	cool	rain	normal	weak	yes
07-10	cool	overcast	normal	strong	yes
07-12	mild	sunny	high	weak	no
07-14	cool	sunny	normal	weak	yes
07-15	mild	rain	normal	weak	yes
07-20	mild	sunny	normal	strong	yes
07-21	mild	overcast	high	strong	yes
07-22	hot	overcast	normal	weak	yes
07-23	mild	rain	high	strong	no
07-26	cool	rain	normal	strong	no
07-30	mild	rain	high	weak	yes

today	cool	sunny	normal	weak	?
tomorrow	mild	sunny	normal	weak	?

Les arbres de décision

Exemple

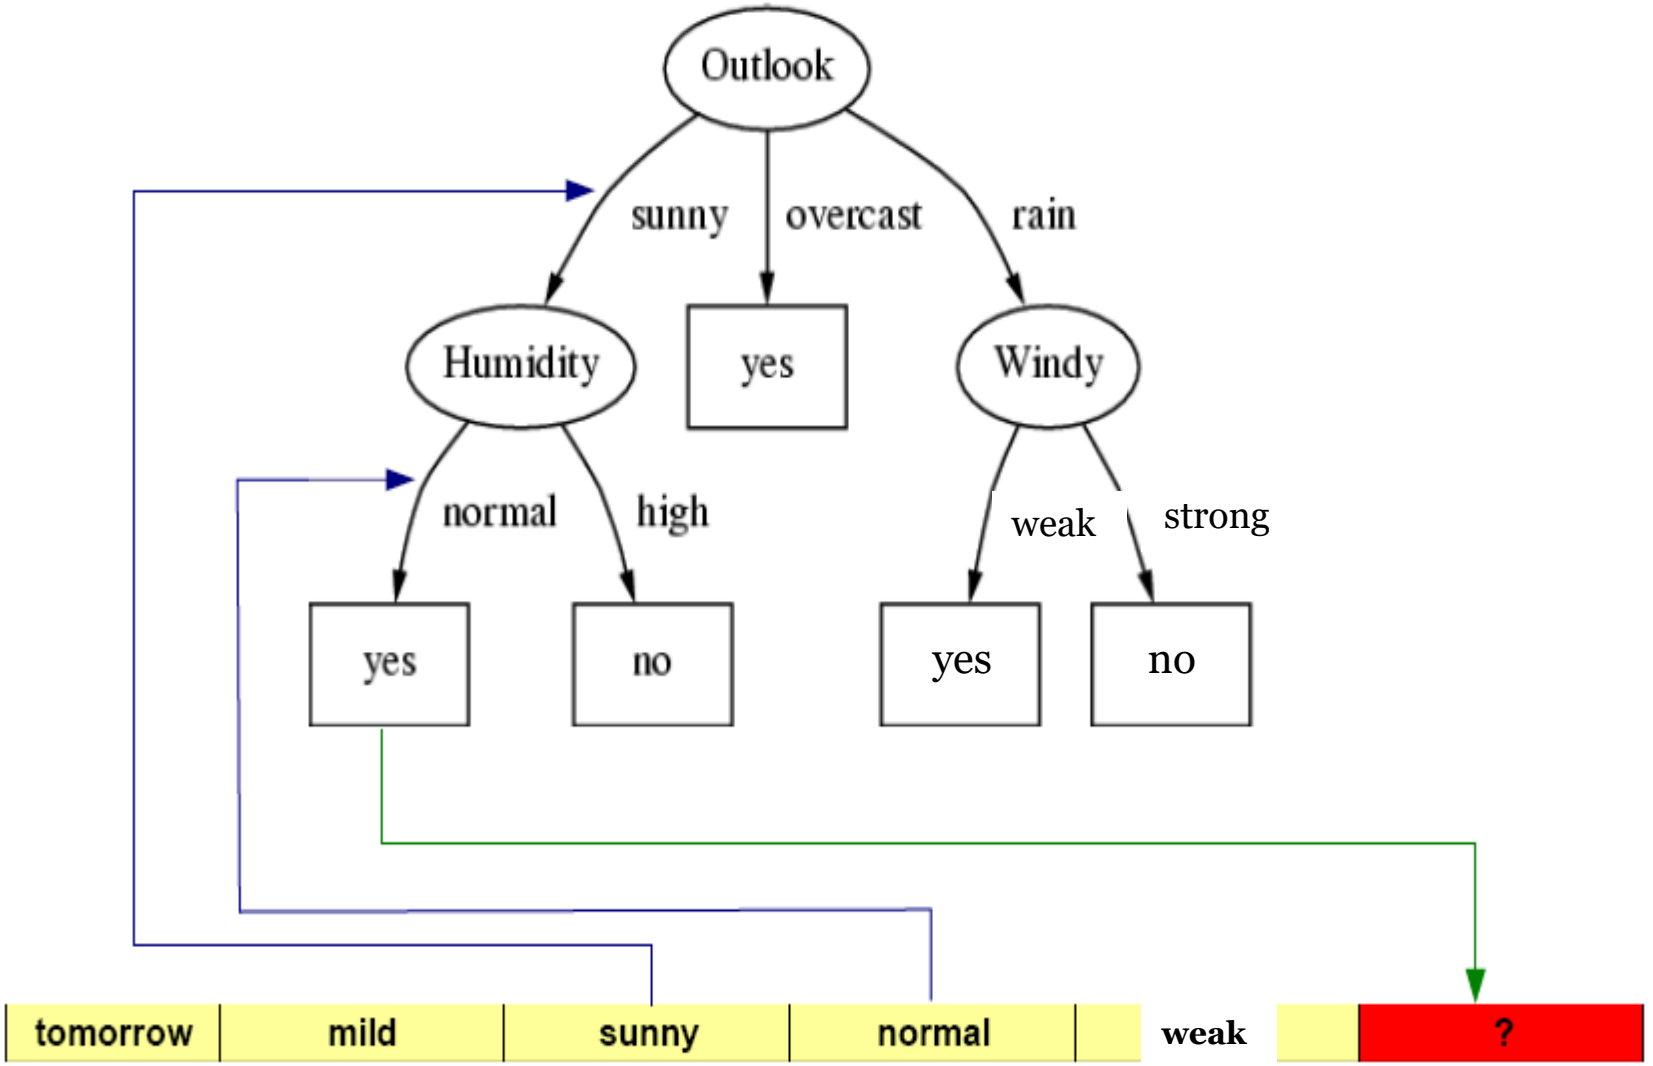

Les arbres de décision

Exemple

Outlook	Humid	Wind
Overcast	High	Weak
Overcast	Normal	Strong
Overcast	High	Strong
Overcast	Normal	Weak

4 yes / 0 no

pure subset

Training examples: **9 yes / 5 no**

Outlook	Humidity	Wind	Play
Sunny	High	Weak	No
Sunny	High	Strong	No
Overcast	High	Weak	Yes
Rain	High	Weak	Yes
Rain	Normal	Weak	Yes
Rain	Normal	Strong	No
Overcast	Normal	Strong	Yes
Sunny	High	Weak	No
Sunny	Normal	Weak	Yes
Rain	Normal	Weak	Yes
Sunny	Normal	Strong	Yes
Overcast	High	Strong	Yes
Overcast	Normal	Weak	Yes
Rain	High	Strong	No

Les arbres de décision

Exemple

Outlook	Humid	Wind
Sunny	High	Weak
Sunny	High	Strong
Sunny	High	Weak
Sunny	Normal	Weak
Sunny	Normal	Strong

2 yes / 3 no

split further

Training examples: **9 yes / 5 no**

Outlook	Humidity	Wind	Play
Sunny	High	Weak	No
Sunny	High	Strong	No
Overcast	High	Weak	Yes
Rain	High	Weak	Yes
Rain	Normal	Weak	Yes
Rain	Normal	Strong	No
Overcast	Normal	Strong	Yes
Sunny	High	Weak	No
Sunny	Normal	Weak	Yes
Rain	Normal	Weak	Yes
Sunny	Normal	Strong	Yes
Overcast	High	Strong	Yes
Overcast	Normal	Weak	Yes
Rain	High	Strong	No

Les arbres de décision

Exemple

Training examples: **9 yes / 5 no**

Outlook	Humidity	Wind	Play
Sunny	High	Weak	No
Sunny	High	Strong	No
Overcast	High	Weak	Yes
Rain	High	Weak	Yes
Rain	Normal	Weak	Yes
Rain	Normal	Strong	No
Overcast	Normal	Strong	Yes
Sunny	High	Weak	No
Sunny	Normal	Weak	Yes
Rain	Normal	Weak	Yes
Sunny	Normal	Strong	Yes
Overcast	High	Strong	Yes
Overcast	Normal	Weak	Yes
Rain	High	Strong	No

Outlook	Humid	Wind
Rain	High	Weak
Rain	Normal	Weak
Rain	Normal	Strong
Rain	Normal	Weak
Rain	High	Strong

3 yes / 2 no

split further

Les arbres de décision

Exemple

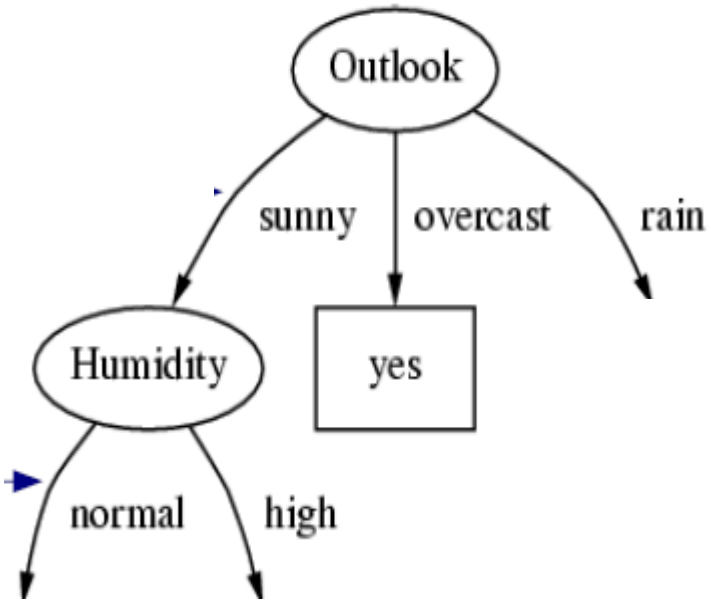

Humid	Wind
Normal	Weak
Normal	Strong

Humid	Wind
High	Weak
High	Strong
High	Weak

Training examples: **9 yes / 5 no**

Outlook	Humidity	Wind	Play
Sunny	High	Weak	No
Sunny	High	Strong	No
Overcast	High	Weak	Yes
Rain	High	Weak	Yes
Rain	Normal	Weak	Yes
Rain	Normal	Strong	No
Overcast	Normal	Strong	Yes
Sunny	High	Weak	No
Sunny	Normal	Weak	Yes
Rain	Normal	Weak	Yes
Sunny	Normal	Strong	Yes
Overcast	High	Strong	Yes
Overcast	Normal	Weak	Yes
Rain	High	Strong	No

Les arbres de décision

Exemple

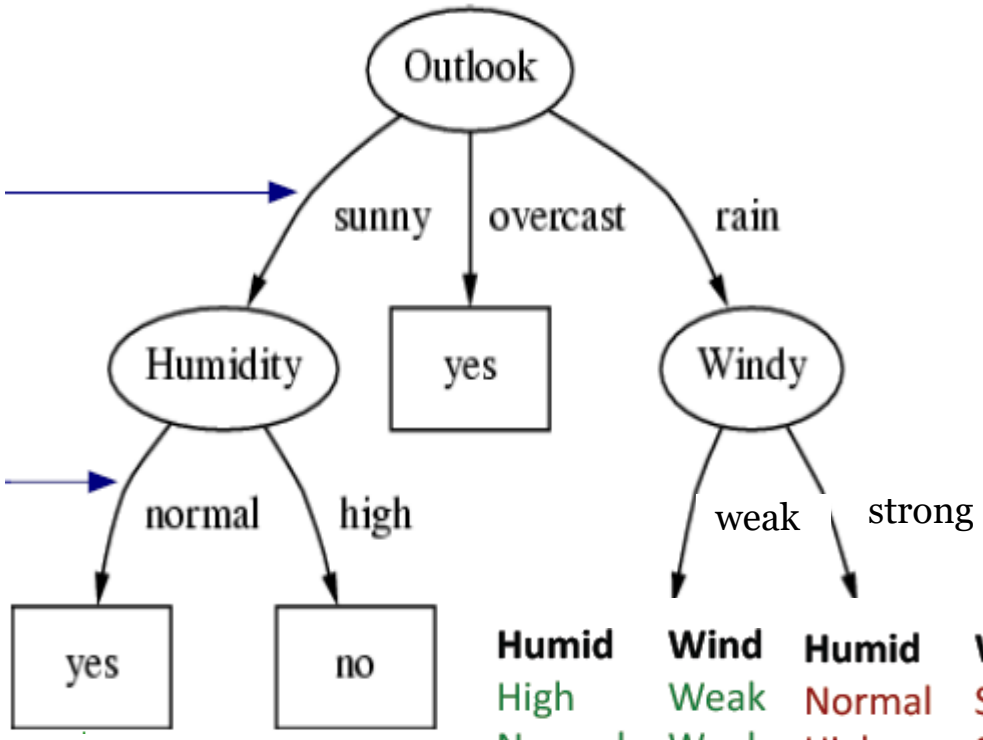

Training examples: **9 yes / 5 no**

Outlook	Humidity	Wind	Play
Sunny	High	Weak	No
Sunny	High	Strong	No
Overcast	High	Weak	Yes
Rain	High	Weak	Yes
Rain	Normal	Weak	Yes
Rain	Normal	Strong	No
Overcast	Normal	Strong	Yes
Sunny	High	Weak	No
Sunny	Normal	Weak	Yes
Rain	Normal	Weak	Yes
Sunny	Normal	Strong	Yes
Overcast	High	Strong	Yes
Overcast	Normal	Weak	Yes
Rain	High	Strong	No

Humid	Wind	Humid	Wind
High	Weak	Normal	Strong
Normal	Weak	High	Strong
Normal	Weak		

Les arbres de décision

Exemple

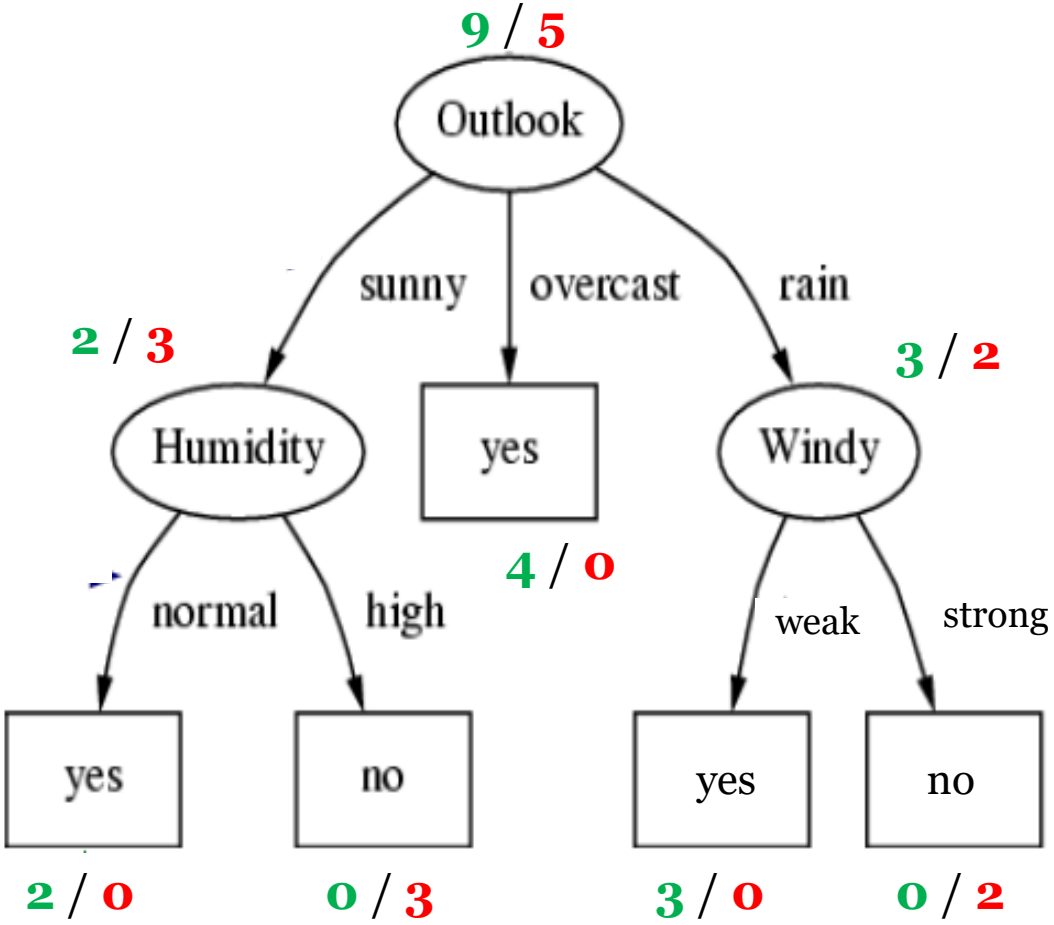

Training examples: **9 yes / 5 no**

Outlook	Humidity	Wind	Play
Sunny	High	Weak	No
Sunny	High	Strong	No
Overcast	High	Weak	Yes
Rain	High	Weak	Yes
Rain	Normal	Weak	Yes
Rain	Normal	Strong	No
Overcast	Normal	Strong	Yes
Sunny	High	Weak	No
Sunny	Normal	Weak	Yes
Rain	Normal	Weak	Yes
Sunny	Normal	Strong	Yes
Overcast	High	Strong	Yes
Overcast	Normal	Weak	Yes
Rain	High	Strong	No

Les arbres de décision

Algorithmes de construction d'arbres de décision

- Diviser pour régner – Divide and Conquer.
- TDIDT: Top-Down Induction of Decision Trees.
- L'arbre est construit récursivement de haut en bas selon le principe « diviser pour régner ».
  - Diviser le problème en sous-problèmes.
  - Résoudre chaque sous-problème.
- Au début, tous les exemples sont dans la racine.
- Ensuite, les exemples sont partitionnés récursivement selon les attributs sélectionnés.

Les arbres de décision

Algorithmes de construction d'arbres de décision

Etapes générales :

1. Sélectionner un attribut pour le nœud racine.
   - Créez une branche pour chaque valeur possible de l'attribut.

2. Diviser les exemples en sous-ensembles.
   - Un pour chaque branche s'étendant à partir du nœud.

3. Répéter récursivement pour chaque branche, en utilisant uniquement les exemples qui atteignent la branche.

4. Arrêter la récursivité pour une branche si tous ses exemples ont la même classe.

Les arbres de décision

Algorithmes de construction d'arbres de décision

Etapes générales :

Le meilleur, le plus pur, comment ?

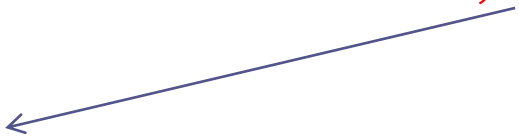

1. **Sélectionner un attribut** pour le nœud racine.
   - Créez une branche pour chaque valeur possible de l'attribut.
2. Diviser les exemples en sous-ensembles.
   - Un pour chaque branche s'étendant à partir du nœud.
3. Répéter récursivement pour chaque branche, en utilisant uniquement les exemples qui atteignent la branche.
4. Arrêter la récursivité pour une branche si tous ses exemples ont la même classe.

Les arbres de décision

Algorithmes de construction d'arbres de décision

Un arbre différent

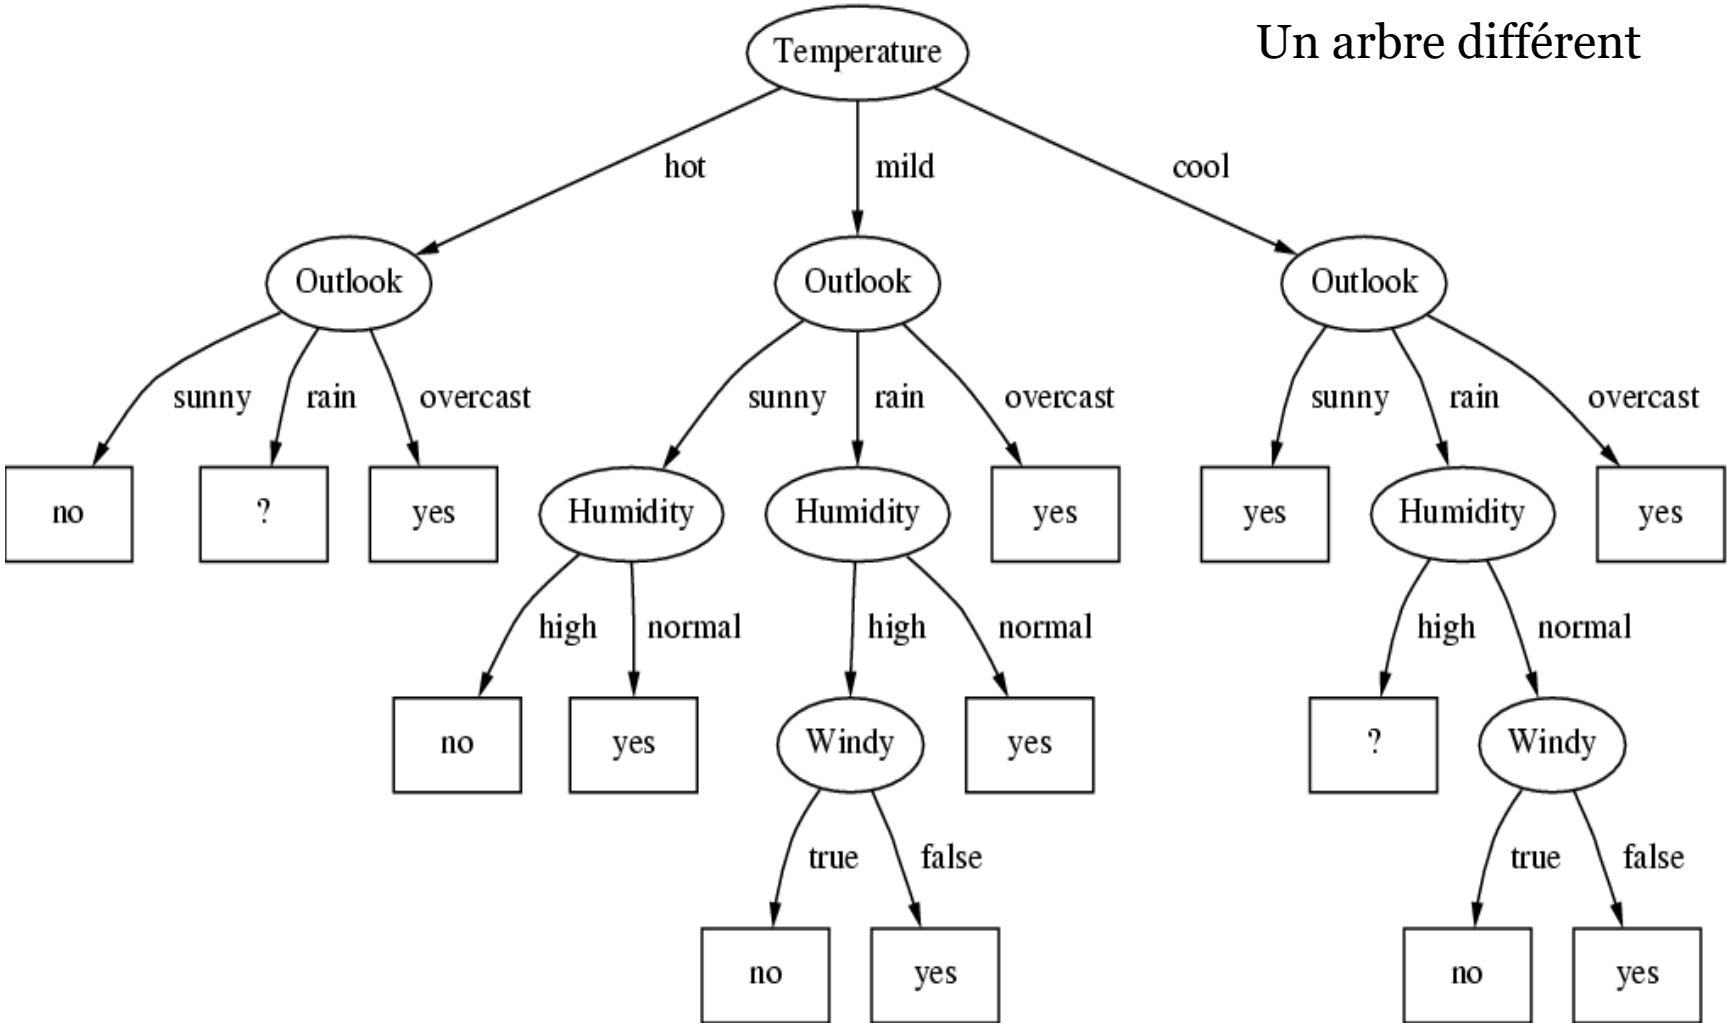

Les arbres de décision

Algorithmes de construction d'arbres de décision

Quel attribut choisir comme racine ?

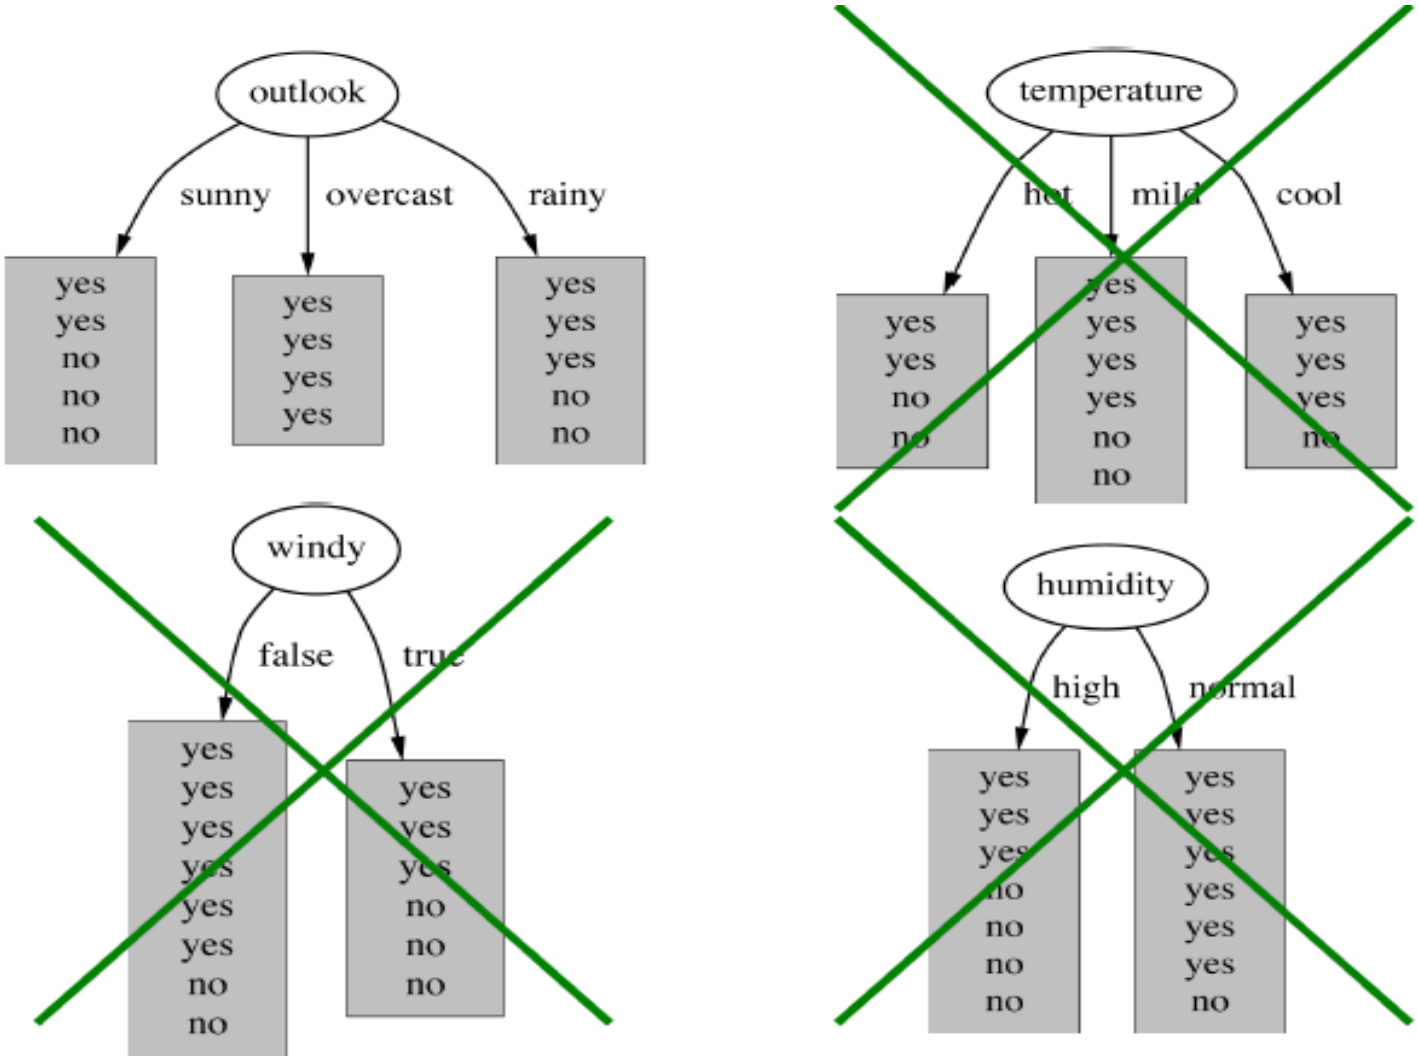

Les arbres de décision

Algorithmes de construction d'arbres de décision

Plusieurs problèmes :

Quel attribut choisir comme racine ?

- Comment choisir l'attribut qui sépare le mieux l'ensemble d'exemples? On parle souvent de la **variable de segmentation (Split)**.
- Comment choisir les critères de séparation d'un ensemble selon l'attribut choisi, et comment ces critères varient selon que l'attribut soit numérique ou symbolique ?
- Quel est le nombre optimal du nombre de critères qui minimise la taille de l'arbre et maximise la précision ?
- Quels sont les critères d'arrêt de ce partitionnement, sachant que souvent l'arbre est d'une taille gigantesque ?

Les arbres de décision

Algorithmes de construction d'arbres de décision

- Un bon attribut préfère les attributs qui divisent les exemples de manière à ce que chaque nœud successeur soit aussi pur que possible.

- i.e. Séparer en sous-ensembles homogènes.

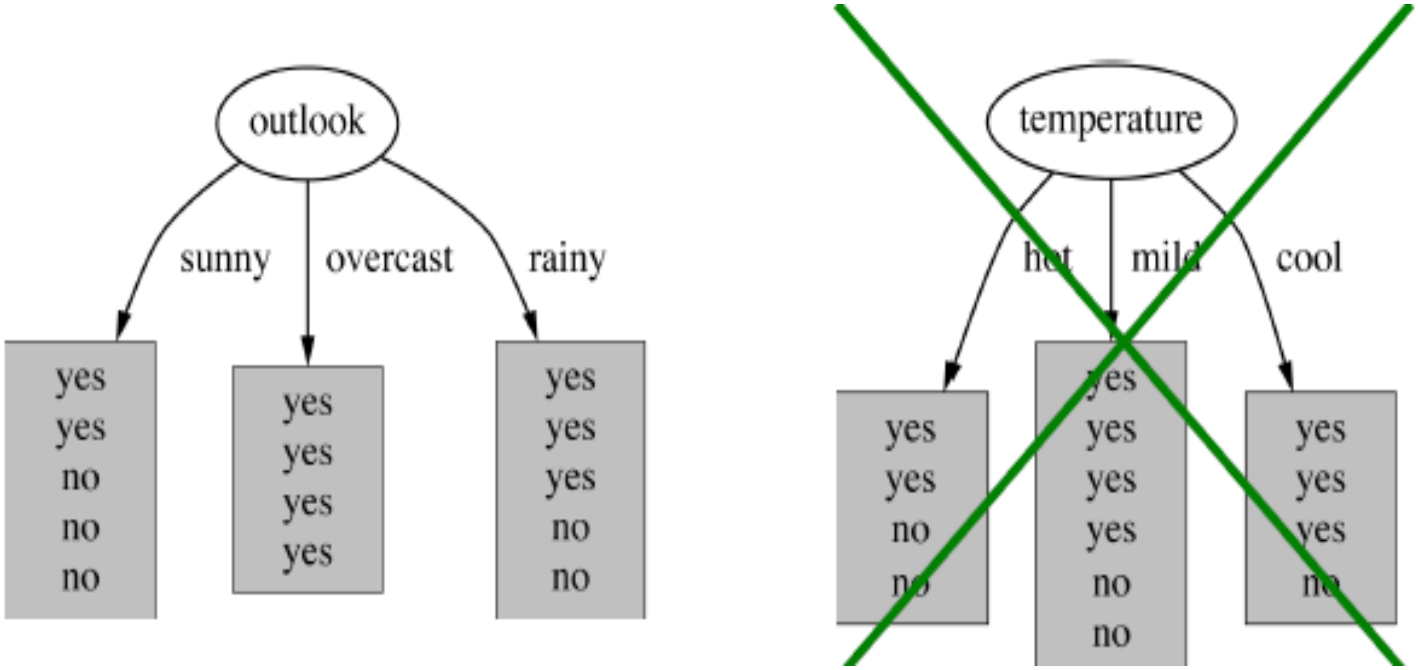

Les arbres de décision

Algorithmes de construction d'arbres de décision

- Comment mesurer la pureté d'un attribut ?

- Différentes mesures :
  - Entropie
  - Gain d'information
  - GainRatio
  - Indice de Gini

- Dépend de l'algorithme choisi.

Algorithme ID3

- ID3 construit l'arbre récursivement.
- Utilise le gain d'information pour mesurer la pureté d'un attribut.
- Son calcul se fait à base de l'entropie de Shannon.
- L'algorithme suppose que tous les attributs sont catégoriels;
- Si des attributs sont numérique, ils doivent être discrétisés.

Algorithme ID3: Pseudo-Code

- Créer nœud N
- **Si** tous les exemples de D sont de la même classe C **alors** Retourner N comme une feuille étiquetée par C ;
- **Si** la liste des attributs est vide **alors** Retourner N Comme une feuille étiquetée de la classe de la majorité dans D ;
- Sélectionner l'attribut A du meilleur Gain dans D ;
- Etiqueter N par l'attribut sélectionné ;
- Liste d'attributs $\leftarrow$ Liste d'attributs - A ;
- **Pour** chaque valeur V_i de A **Faire**
  - Soit D_i l'ensemble d'exemples de D ayant la valeur de $A = V_i$;
  - Attacher à N le sous arbre généré par l'ensemble Di et la liste d'attributs
- **FinPour ;**
- **Fin ;**

Choix d'attribut: Entropie

- Supposons qu'il y a deux classes : **Yes** et **No**.
- Soit l'ensemble d'exemples ***S*** contenant *p* exemples de la classe **Yes** et *n* exemples de la classe **No.**
- L'entropie est la quantité d'information nécessaire pour décider qu'un exemple dans ***S*** appartienne à Yes ou No.
- Elle est définie par :

$$E(S) = -p_+ \log_2(p_+) - p_- \log_2(p_-)$$

Où, p_+ est la proportion des exemples Yes,

et p_- est la proportion des exemples No

Choix d'attribut: Entropie

$$E(S) = -p_+ \log_2(p_+) - p_- \log_2(p_-)$$

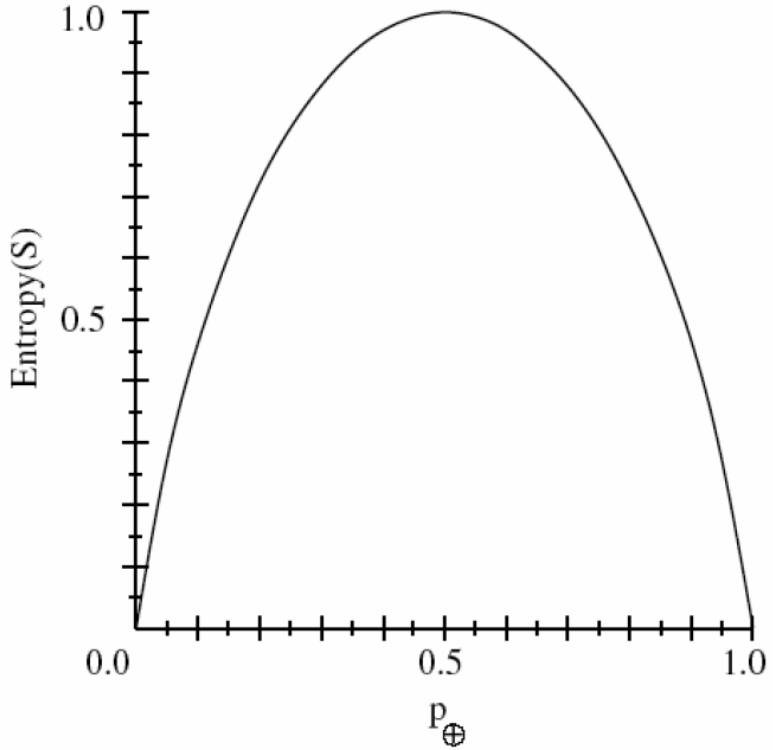

- Se mesure en **bits**.
- Si tous exemples sont soit tous Yes, soit tous No, l'entropie est nulle.
- Si p+ = p- = 0.5 alors l'entropie est égale à 1.

Exemple : 9+ 5-

$$E(S) = E([9+,5-]) = -\frac{9}{14}\log_2(\frac{9}{14}) - \frac{5}{14}\log_2(\frac{5}{14}) = 0.940$$

Choix d'attribut: Entropie

$$E(S) = -p_+ \log_2(p_+) - p_- \log_2(p_-)$$

Cas de plus de 2 classes :

$$E(S) = -p_1 \log p_1 - p_2 \log p_2 \ldots - p_n \log p_n = -\sum_{i=1}^{n} p_i \log p_i$$

Choix d'attribut: Gain d'information

- L'entropie ne calcule que la qualité d'un seul (sous) ensemble d'exemples.
  - Correspond à une valeur unique.
- Comment calculer la qualité de l'ensemble du Split ?
  - Correspond à un attribut entier.
- => Gain d'information pour un attribut A : **G(S, A)**

$$Gain(S,A) = E(S) - \sum_{v \in valeurs(A)} \frac{|S_v|}{|S|} E(S_v)$$

- L'attribut qui maximise cette différence est sélectionné.

Les arbres de décision

Choix d'attribut: Gain d'information

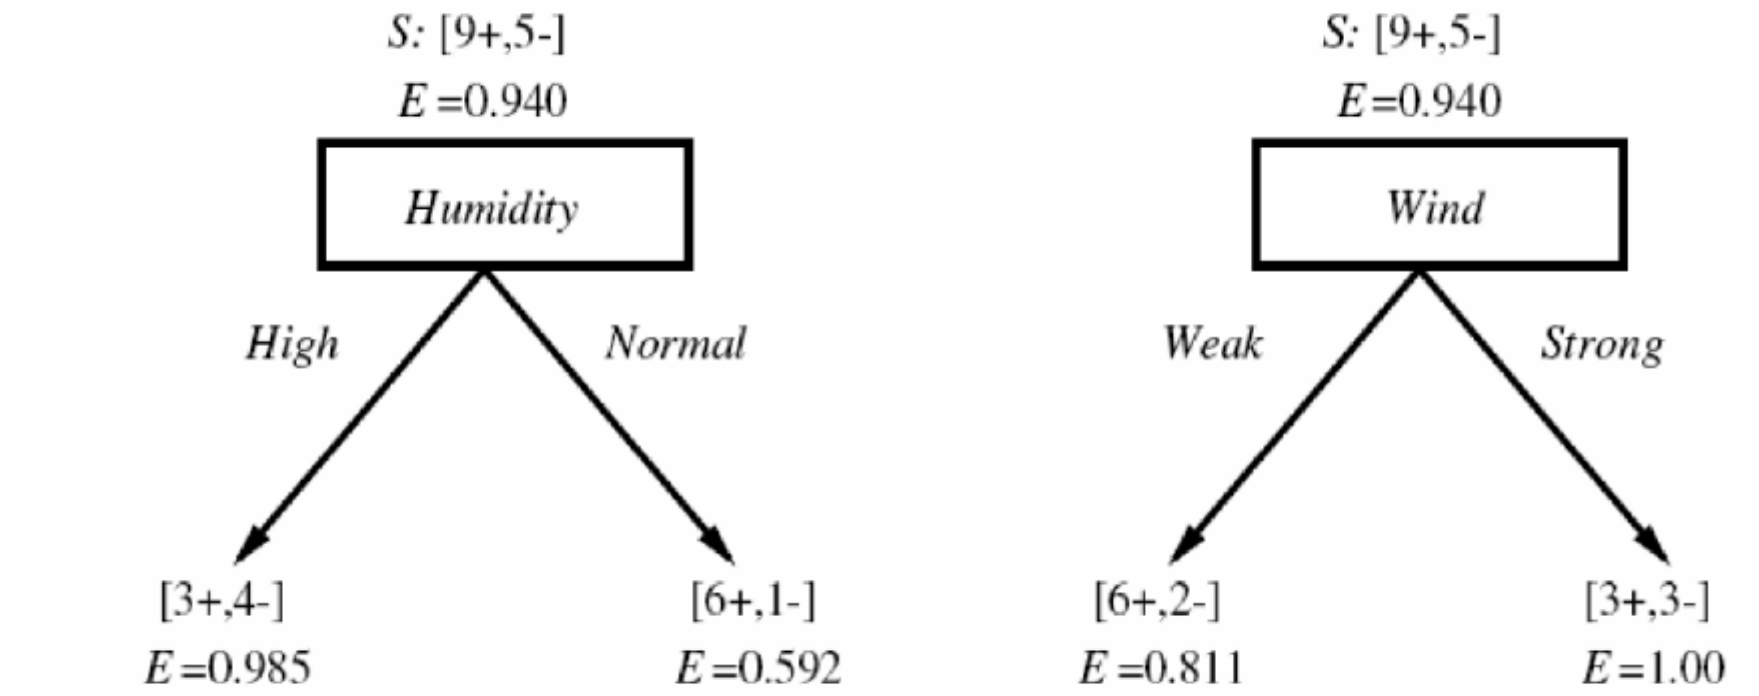

Gain (S, Humidity)
= .940 - (7/14).985 - (7/14).592
= .151

Gain (S, Wind)
= .940 - (8/14).811 - (6/14)1.0
= .048

$Gain(S, Outlook) = 0.246$

$Gain(S, Temperature) = 0.029$

Les arbres de décision

<u>Choix d'attribut</u>: Gain d'information

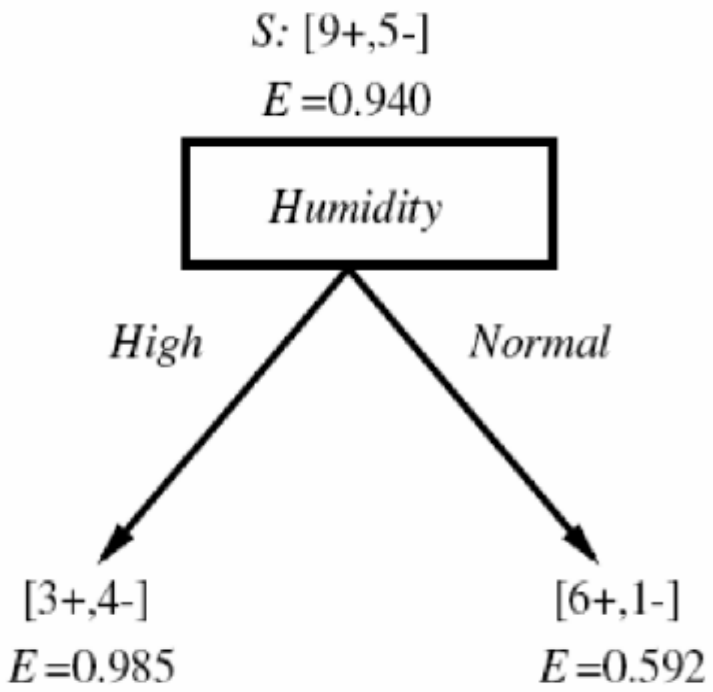

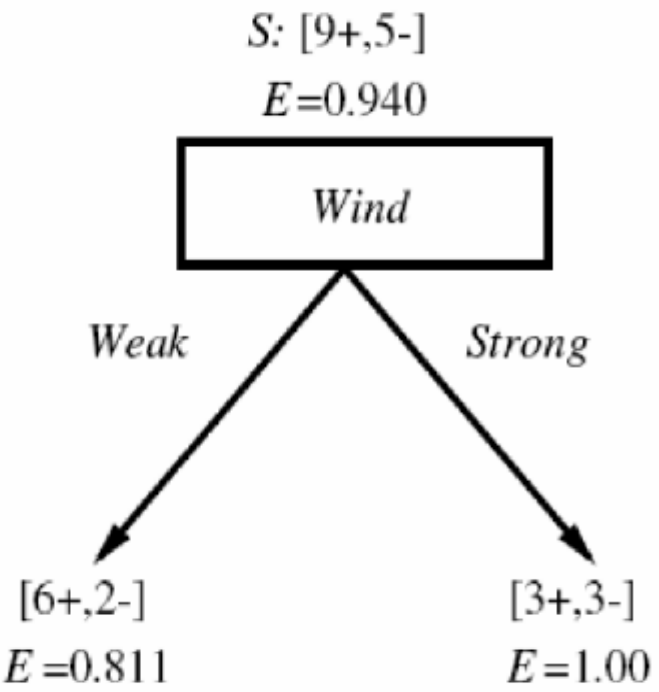

Gain (S, Humidity)
= .940 - (7/14).985 - (7/14).592
= .151

Gain (S, Wind)
= .940 - (8/14).811 - (6/14)1.0
= .048

$Gain(S, Outlook) = 0.246$

$Gain(S, Temperature) = 0.029$

Les arbres de décision

Choix d'attribut: Gain d'information

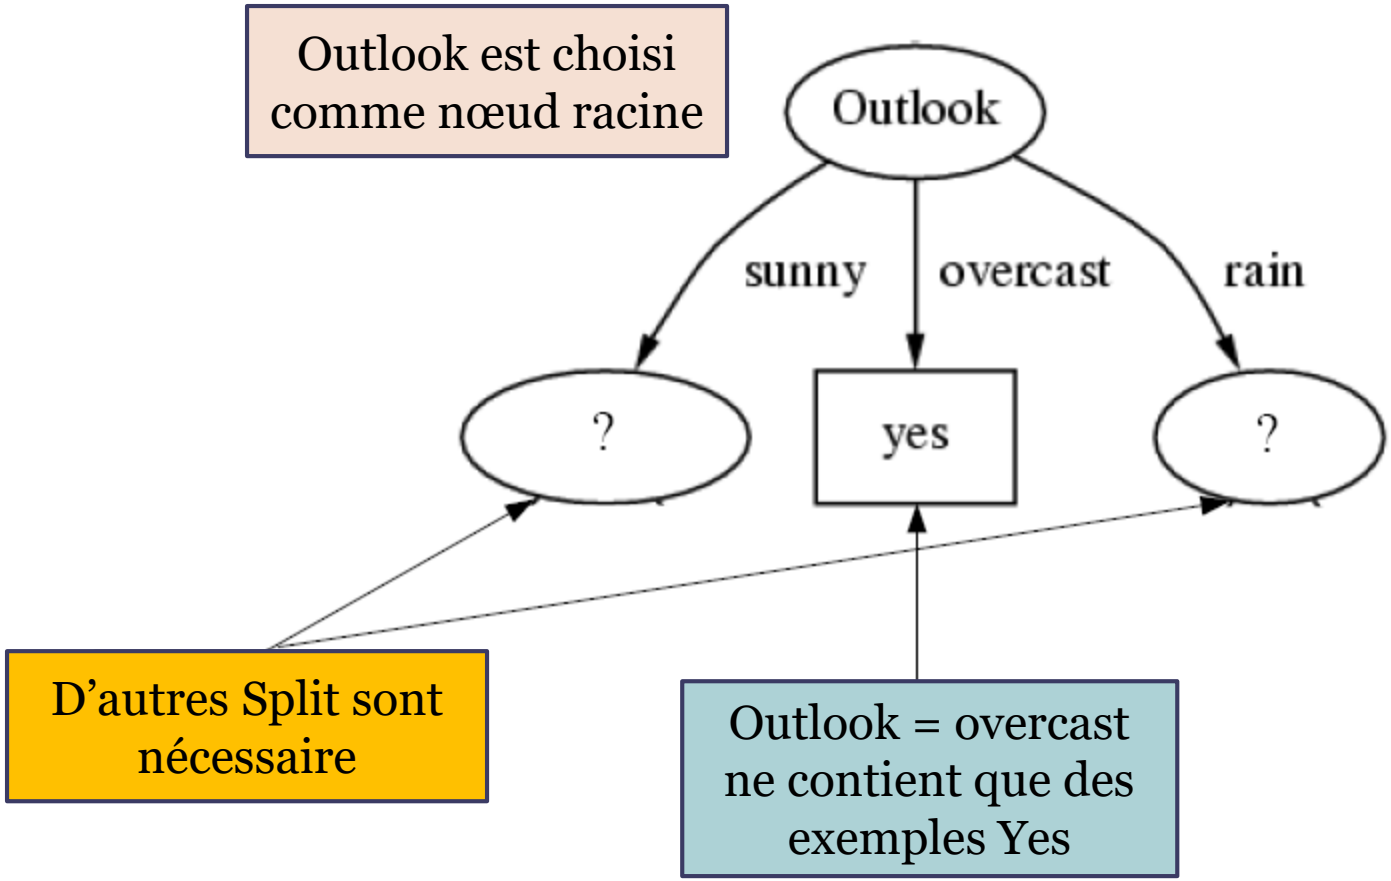

Les arbres de décision

Choix d'attribut: Gain d'information

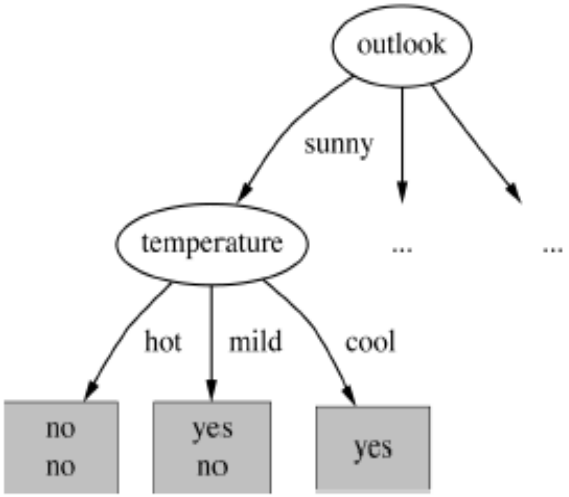

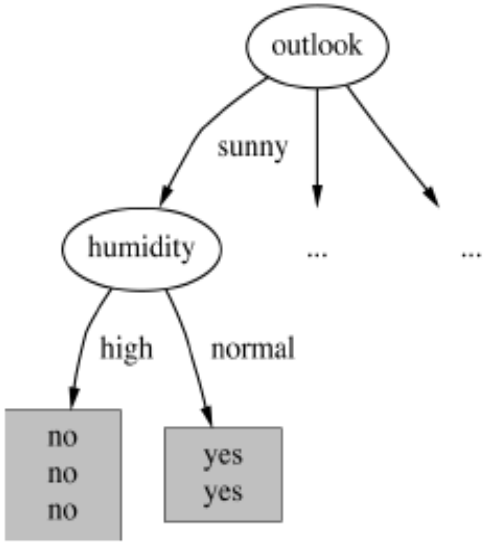

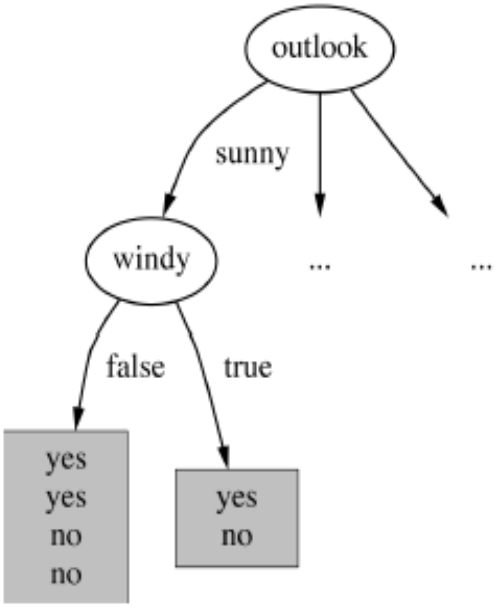

Gain(*Temperature*)
Gain(*Humidity*)
Gain(*Windy*)

$$S \Rightarrow S_{sunny}$$

Les arbres de décision

Choix d'attribut: Gain d'information

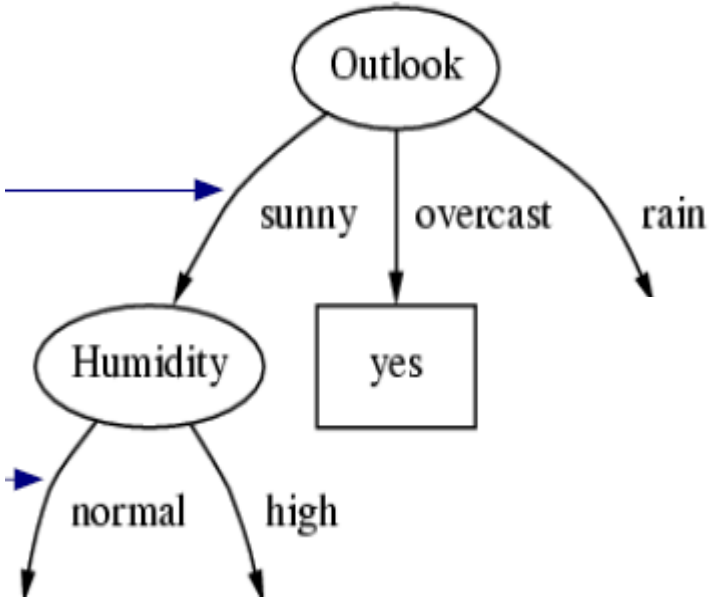

Humid	Wind	Humid	Wind
Normal	Weak	High	Weak
Normal	Strong	High	Strong
		High	Weak

$$Gain(S_{Sunny}, Humidity) = E(S_{Sunny}) - \sum_{v \in valeurs(Humidity)} \frac{|S_{Sunny-v}|}{|S|} E(S_{Sunny-v})$$

Choix d'attribut: Gain d'information

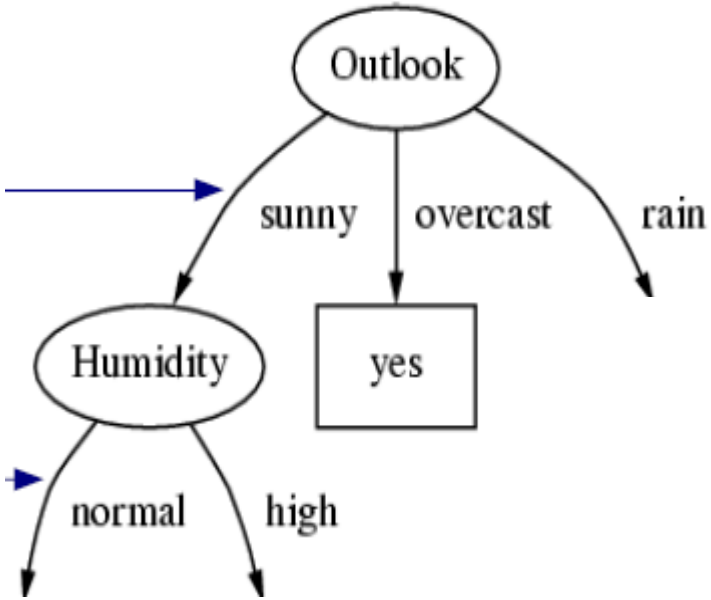

Humid	Wind	Humid	Wind
Normal	Weak	High	Weak
Normal	Strong	High	Strong
		High	Weak

$$E(S_{Sunny}) = E([2+,3-]) = -\frac{2}{5}\log_2(\frac{2}{5}) - \frac{3}{5}\log_2(\frac{3}{5}) = 0.971$$

Les arbres de décision

Choix d'attribut: Gain d'information

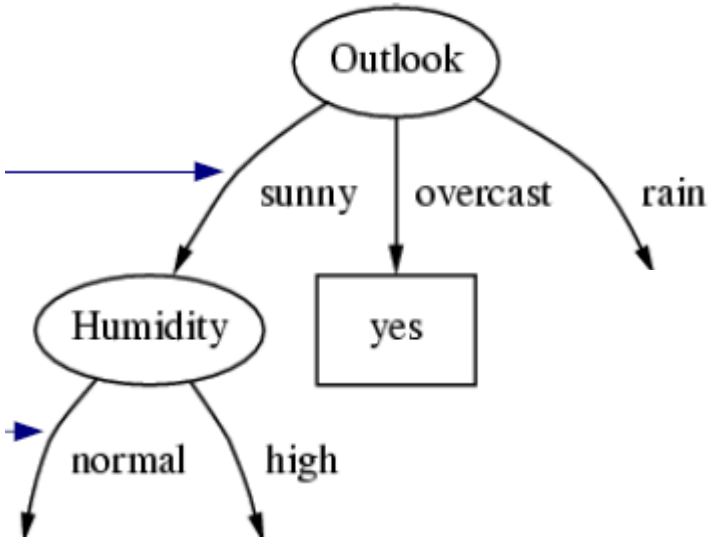

Humid	Wind	Humid	Wind
Normal	Weak	High	Weak
Normal	Strong	High	Strong
		High	Weak

$$\sum_{v \in valeurs(Humidity)} \frac{|S_{Sunny-v}|}{|S|} E(S_{Sunny-v})$$

Les arbres de décision

Choix d'attribut: Gain d'information

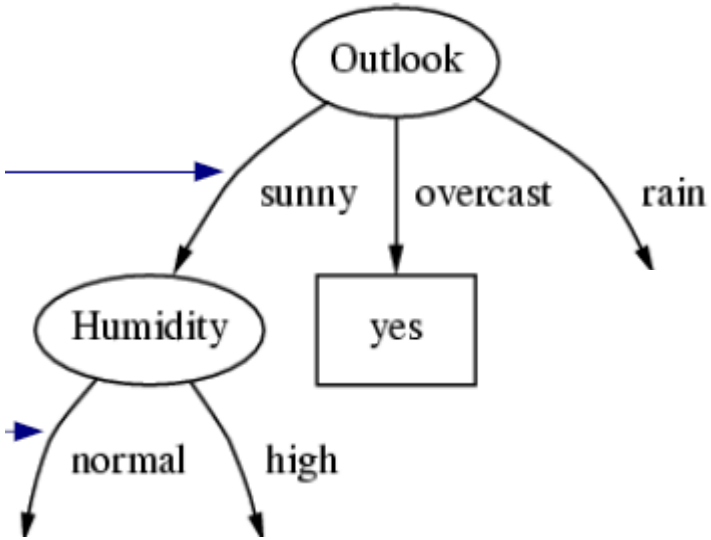

Humid	Wind	Humid	Wind
Normal	Weak	High	Weak
Normal	Strong	High	Strong
		High	Weak

$$= \frac{|S_{Sunny-High}|}{|S_{Sunny}|} E(S_{Sunny-High}) + \frac{|S_{Sunny-Normal}|}{|S_{Sunny}|} E(S_{Sunny-Normal})$$

Choix d'attribut: Gain d'information

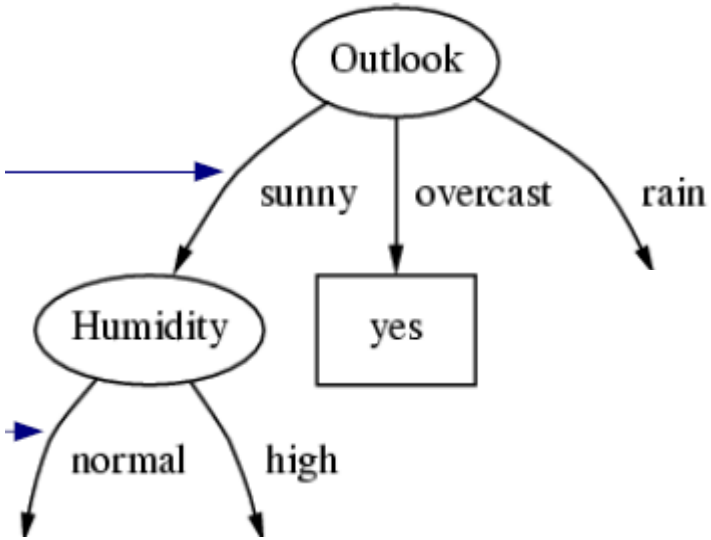

Humid	Wind	Humid	Wind
Normal	Weak	High	Weak
Normal	Strong	High	Strong
		High	Weak

$$= \frac{3}{5} E([3+,0-]) + \frac{2}{5} E([0+,2-])$$

Choix d'attribut: Gain d'information

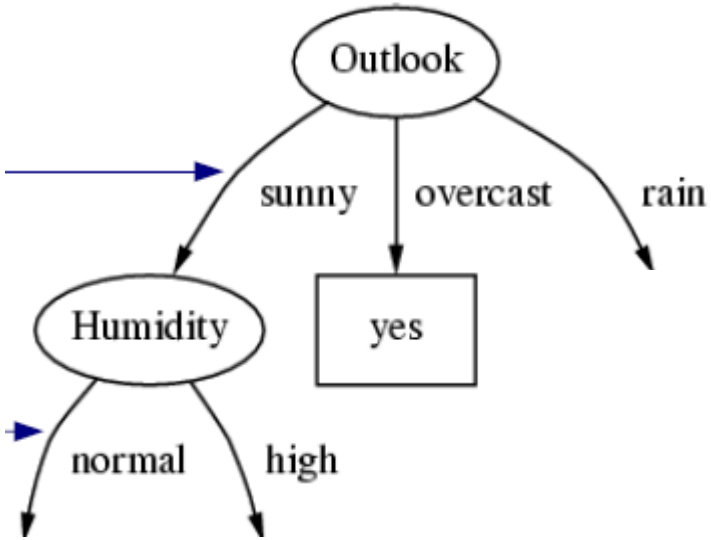

Humid	Wind	Humid	Wind
Normal	Weak	High	Weak
Normal	Strong	High	Strong
		High	Weak

$$= 0.971 - (\frac{3}{5} * 0) + \frac{2}{5} * 0) = 0.971$$

Les arbres de décision

Choix d'attribut: Gain d'information

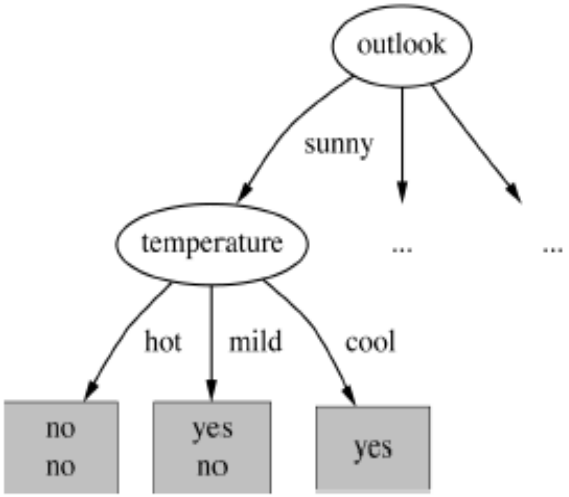

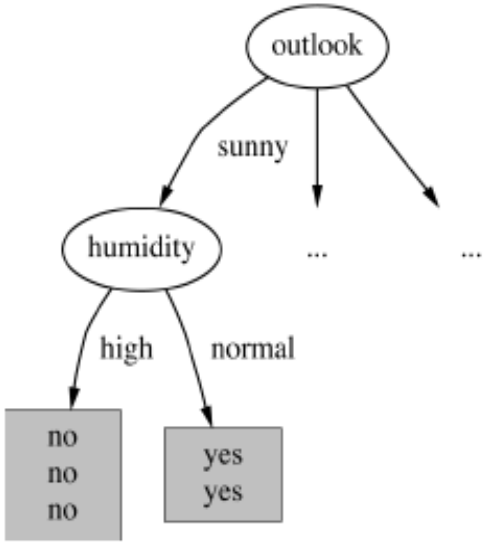

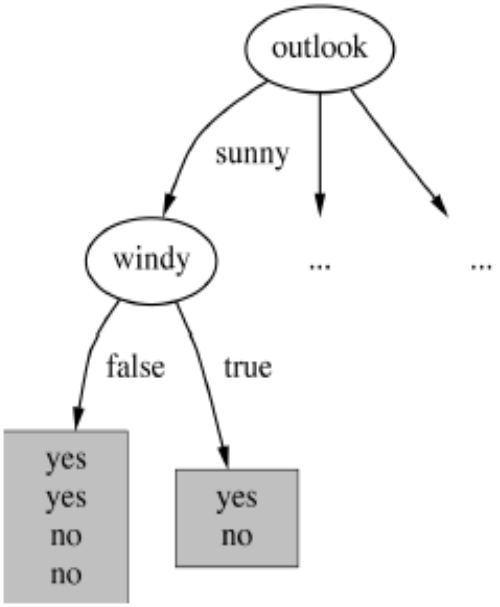

$$\left.\begin{aligned} \text{Gain}(\textit{Temperature}) &= 0.571 \text{ bits} \\ \text{Gain}(\textit{Humidity}) &= 0.971 \text{ bits} \\ \text{Gain}(\textit{Windy}) &= 0.020 \text{ bits} \end{aligned}\right\}$$

Les arbres de décision

Choix d'attribut: Gain d'information

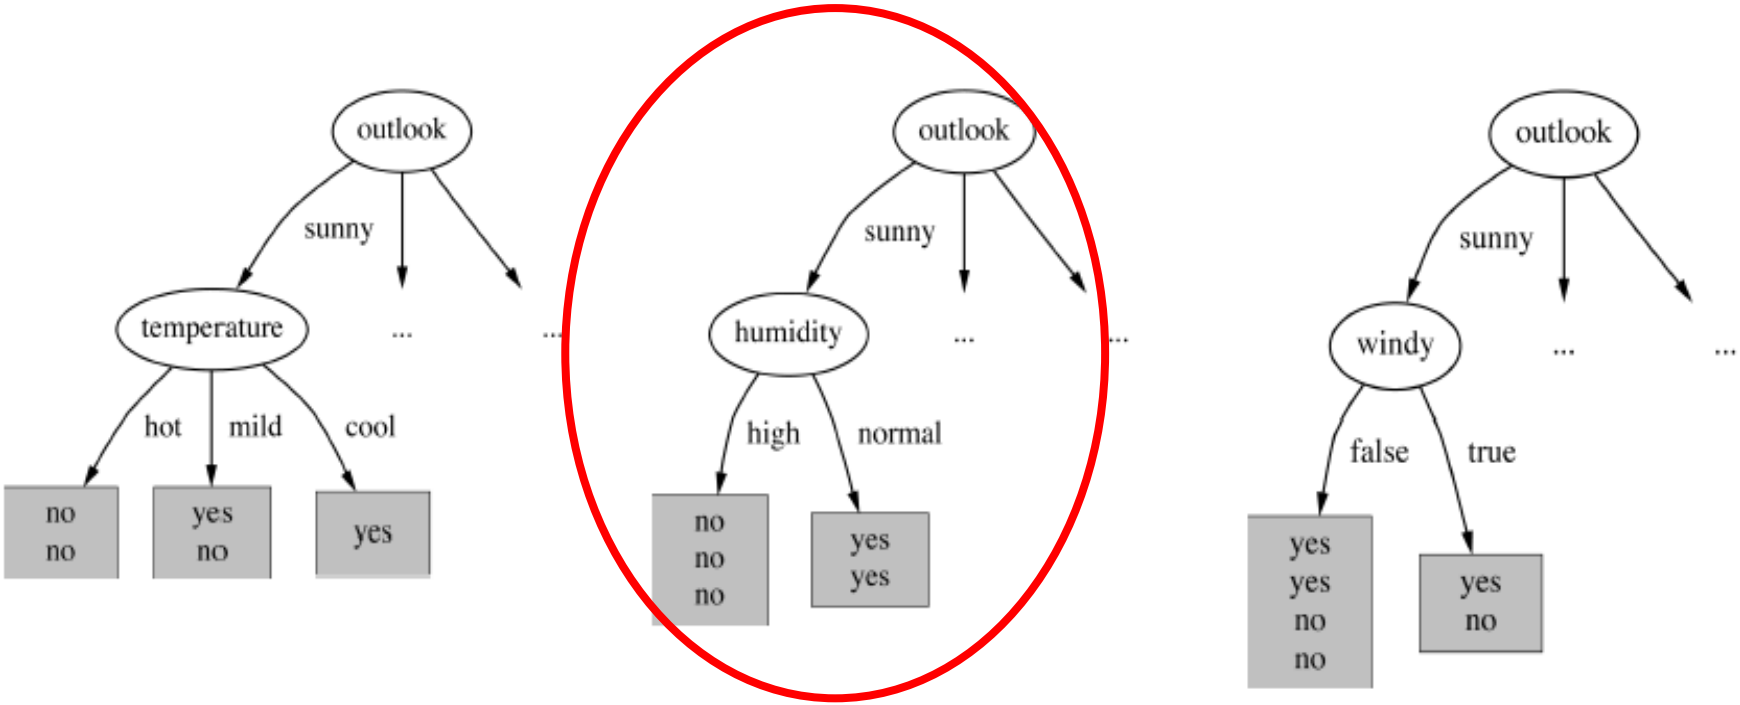

Gain(*Temperature*) = 0.571 bits
Gain(*Humidity*) = 0.971 bits
Gain(*Windy*) = 0.020 bits

Humidity est choisi

Les arbres de décision

D'autres algorithmes

- Algorithme C4.5 (J48)
  - Amélioration de ID3
  - Prends en compte les attributs numériques.
  - Utilise le GainRation pour le Split/Segmentation.

- Algorithme CART
  - CART : Classification And Regression Trees.
  - Utilise l'indice de Gini pour le Split/Segmentation.

- Forêts aléatoires
  - Plus efficaces mais difficilement interprétables.
  - Construction des arbres se base sur le Bootstrap (ou le Bagging).

Ressources

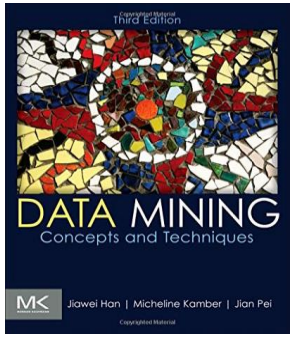

Data Mining : concepts and techniques, 3rd Edition

- ✓ Auteur : Jiawei Han, Micheline Kamber, Jian Pei
- ✓ Éditeur : Morgan Kaufmann Publishers
- ✓ Edition : Juin 2011 - 744 pages - ISBN 9780123814807

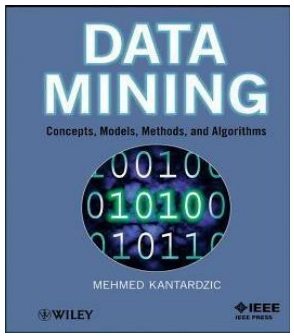

Data Mining : concepts, models, methods, and algorithms

- ✓ Auteur : Mehmed Kantardzi
- ✓ Éditeur : John Wiley & Sons
- ✓ Edition : Aout 2011 – 552 pages - ISBN : 9781118029121

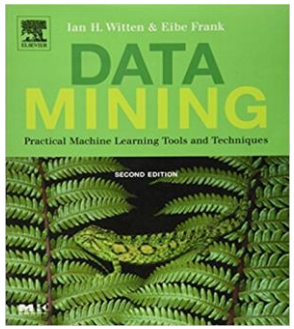

Data Mining: Practical Machine Learning Tools and Techniques

- ✓ Auteur : Ian H. Witten & Eibe Frank
- ✓ Éditeur : Morgan Kaufmann Publishers
- ✓ Edition : Juin 2005 - 664 pages - ISBN : 0-12-088407-0

Ressources

Cours – Abdelhamid DJEFFAL – Fouille de données avancée

- ✓ www.abdelhamid-djeffal.net

WekaMOOC – Ian Witten – Data Mining with Weka

- ✓ https://www.youtube.com/user/WekaMOOC/featured

Cours - Laboratoire ERIC Lyon - DATA MINING et DATA SCIENCE

- ✓ https://eric.univ-lyon2.fr/~ricco/cours/supports_data_mining.html

Gregory Piatetsky-Shapiro - KDNuggets

- ✓ http://www.kdnuggets.com/