NLP - Série TD 2 - Traitements Niveau Lexical

Exercice 1

Ecrire une fonction nommée ***get_all_morphems*** permettant de prendre comme paramètre une liste de mots en anglais nommée *words* **et** une liste de suffixes nommée *suffixes*, puis de retourner un dictionnaire nommé *morphems* qui contient tous les morphèmes dans *words* selon leur typologie, comme suit :

morphems = {

"free_lexical" : [liste de tous les morphèmes libres lexicaux dans words],

"free_functional" : [liste de tous les morphèmes libres grammaticaux dans words],

"bound_inflectional" : [liste de tous les morphèmes liés flexionnels dans words],

"bound_derivational" : [liste de tous les morphèmes liés dérivationnels dans words],

}

On donne les listes suivantes, déclarées :

functional_words = ["the", "a", "an", "and", "or", "but", …]

inflectional_suffixes = ["s", "es", "ed", "ing", "er", …]

NB : Vous pouvez utiliser la méthode pour chaines de caractères *str*.***endswith***(str): returns Boolean, pour tester si une chaine de caractère se termine par une autre chaine (groupe) de caractères.

Exercice 2

Dérouler l'algorithme Porter Stemmer afin d'extraire les stems des mots : « hapiness », « responsibilities », « unabled » et « sensational ». Voir le cours 3 pour les étapes de l'algorithme.

Exercice 3

Soit le corpus C annoté (POS taggé) en anglais. Chaque mot est associé à une étiquette morphosyntaxique (POS tag) :

Book a car	**V DT N**	Book/V a/DT car/N
Park the car	**V DT N**	Park/V the/DT car/N
The book is in the car	**DT N V P DT N**	The/DT book/N is/V in/P the/DT car/N
The car is in a park	**DT N V P DT N**	The/DT car/N is/V in/P a/DT park/N
Book bag	**N N**	Book/N bag/N

Un modèle de Markov caché (HMM) pour le POS Tagging repose sur deux types de probabilités :

- Probabilités de transition : La probabilité de passer d'un POS tag à un autre.

- Probabilités d'émission : La probabilité qu'un mot soit généré par un POS tag donné.

À partir du corpus C, l'entrainer afin de :

1. Calculer les probabilités (table) de transition entre les POS tags.
2. Calculer les probabilités (table) d'émission pour chaque mot du corpus.
3. Calculer les probabilités initiales.

Vous devez maintenant étiqueter une nouvelle séquence de mots en utilisant le modèle HMM que vous avez appris : « **Book the park** »

4. Utilisez l'algorithme de Viterbi pour déterminer la séquence de POS tags la plus probable pour cette phrase.

Exercice 4

Dérouler l'algorithme Soundex pour les mots suivants : Robert, Algeria, Processing. Avec :

- 1 = B, F, P, V
- 2 = C, G, J, K, Q, S, X, Z
- 3 = D, T
- 4 = L
- 5 = M, N
- 6 = R